



CENTRALE
LYON



Soutenance Finale


PAr 133 – La génération de contenu procédurale

29 avril 2026

Élèves : Jincheng HUANG, Rongxin LI

Tuteurs : Mohsen ARDABILIAN, Alexandre SAIDI

Conseiller : Manuel COBIAN



Sommaire

I – Contexte

II – Etat de l'art


III – Comparaison des modèles de SR


**IV – Interface interactive et
démonstration d'usage**

V – Organisation des tâches


Conclusion

Bibliographie





PAr en 2022 : Création
d'un générateur de
niveau pour un jeu.



PAr en 2023 : Musique-Image



PAr en 2024 : générer des motifs complexes et divers à partir d'un
ensemble limité d'exemples initiaux (l'approche hybride **VQ-VAE/WFC**)

Génération de contenu procédural

(PCG) :

- jeux vidéo
- cinéma et de la télévision
- formation (texte et dialogue)
- audio
- ...

Génération d'images et de
textures de
super-résolution (SR)



Partie théorique

- Connaissance des principes fondamentaux de la génération procédurale
- Revue et analyse des **méthodes** de SR :
 - Méthodes classiques
 - Méthodes basées sur l'apprentissage profond .



Partie fonctionnelle

- Générer des différentes images **haute résolution (HR)** à partir d'images **basse résolution (LR)** à l'aide des différentes modèles
- Analyse qualitative et quantitative des images générées




$$I_x^{LR} = d(I_y^{HR}; \theta).$$

inverse
➔

$$\hat{I}_y^{HR} = I_y^E = g(I_x^{LR}; \theta) \approx d^{-1}(I_x^{LR})$$

La fonction de perte

$$\hat{f} = \arg \min_f \mathcal{L}(I_y^E, I_y^{HR}) + h \phi(f)$$



SRSI : la single-image super-resolution

- l'image LR résulte d'un processus de dégradation appliqué à une image HR : sous-échantillonnage, flou, bruit, etc.
- chercher à apprendre une fonction de **reconstruction** qui approxime l'inverse de cette dégradation.

Méthodes classiques

- **Les méthodes d'interpolation :** l'interpolation au plus proche voisin, bilinéaire et bicubique
- **Les méthodes fréquentielles :** les relations spectrales
- **Les méthodes par régularisation ou contraintes :** connaissances a priori



limites en termes de restitution
des détails et de robustesse

Méthodes basées sur l'apprentissage profond

- **Méthodes d'upsampling:** l'opération d'agrandissement (suréchantillonnage), une interpolation fixe → des modules d'upsampling apprenables
- **Optimisation des paramètres :** Apprentissage Supervisé, Apprentissage non supervisées, la fonction de perte

$$\mathcal{L}_{\text{Cont}}(I_{SR}, I_y, \phi) = \frac{1}{h_l w_l c_l} \sum_{i,j,k} \left(\phi_{(l)}^{i,j,k}(I_{SR}) - \phi_{(l)}^{i,j,k}(I_y) \right)^2$$

Comparaison des modèles de SR

modèles choisis


ESPCN — Efficient Sub-Pixel CNN

Pipeline

LR $\rightarrow$ 3 conv $\rightarrow$ PixelShuffle $\rightarrow$ SR

Caractéristiques

- Conversion YCbCr ; super-résolution sur le canal Y uniquement
- CbCr interpolés bilinéairement, puis recombinaison
- Modèle très léger (quelques milliers de paramètres)
- Inférence en quelques secondes, même sans GPU



Source : Wenzhe Shi *et al.*, 2016


Real-ESRGAN — Enhanced SRGAN

Architecture

Générateur RRDB + Discriminateur U-Net

Caractéristiques

- Modèle de dégradation à 2 étages : flou + bruit + JPEG
- Entraîné pour les dégradations du « monde réel »
- Poids pré-entraînés $\times 2$ et $\times 4$
- Excellente robustesse perceptuelle



Source : Xintao Wang *et al.*, 2018

Comparaison des modèles de SR

modèles choisis

SwinIR — Swin Transformer pour la SR

Architecture




Figure 2: The architecture of the proposed SwinIR for image restoration.


Entraînement

- Pré-entraîné sur DF2K (Flickr2K + DIV2K)
- Trois poids disponibles : $\times 2$, $\times 3$, $\times 4$ (taille M)
- Capture des dépendances longue distance

Source: Liang et al., 2021

CoSeR — Cognitive Super-Resolution

Architecture (modèle de diffusion)



Pipeline d'inférence

LR $\rightarrow$ padding $\rightarrow$ 512 $\times$ 512 $\rightarrow$ VQGAN $\rightarrow$ Q-Former $\rightarrow$ UNet $\rightarrow$ DDIM $\rightarrow$ décodeur $\rightarrow$ recadrage $\rightarrow$ SR

Source : Sun et al. en 2024

Comparaison des modèles de SR

modèles choisis

ESPCN

CNN léger

« Le rapide »

Inférence quasi instantanée. Très peu de paramètres.

Adapté aux environnements à ressources limitées.

Real-ESRGAN

GAN

« Le réaliste »

Robuste aux dégradations réelles (flou, bruit, JPEG). Bon rendu perceptuel sur photos abîmées.

SwinIR

Transformer

« Le précis »

Meilleures métriques PSNR/SSIM. Capture des dépendances longue distance dans l'image.

CoSeR

Diffusion

« Le créatif »

Génère les détails les plus riches. Pipeline génératif guidable par prompt textuel.

Comparaison des modèles de SR



Méthodologie d'évaluation

Jeu de données

Set14

benchmark de référence, 14 images

Facteurs évalués

×2

×3

×4

4 modèles × 3 facteurs = 12 expériences

Dégradation : interpolation bicubique ($LRbic_{\{2,3,4\}}$)

Trois métriques complémentaires

PSNR

canal Y (BT.601)

Fidélité pixel — plus élevé = meilleur

SSIM

canal Y, fenêtre 11, $\sigma=1.5$

Similarité structurelle — plus élevé = meilleur


LPIPS

RGB, AlexNet

Qualité perceptuelle — plus faible = meilleur

Comparaison des modèles de SR

Pipeline expérimental



Cas particulier — CoSeR


CoSeR génère toujours une sortie native **×4** (entrée paddée à 512×512). Pour évaluer en ×2 et ×3 :

- Recadrage des bordures noires (taille originale × 4)
- Redimensionnement bicubique vers le facteur cible
- Le GT est redimensionné proportionnellement pour aligner les dimensions

Résultats quantitatifs

Modèle	Facteur d'échelle	PSNR (dB) ↑	SSIM ↑	LPIPS ↓
SwinIR	×2	34.41	0.9250	0.083
	×3	30.92	0.8540	0.190
	×4	29.08	0.7950	0.268
ESPCN	×2	32.32	0.9060	0.107
	×3	29.20	0.8200	0.236
	×4	27.40	0.7500	0.331
Real-ESRGAN	×2	28.16	0.8110	0.154
	×3	26.63	0.7620	0.189
	×4	25.40	0.6960	0.236
CoSeR	×2	24.51	0.7440	0.130
	×3	24.26	0.6890	0.180
	×4	24.02	0.6500	0.227

Résultats qualitatifs



ESPCN


Real-ESRGAN

SwinIR

CoSeR



HR



LR

Résultats qualitatifs



HR

ESPCN

Real-ESRGAN

SwinIR

CoSeR

Cas d'usage

- Imagerie médicale et satellitaire
- Sécurité et vidéosurveillance
- Restauration de photos anciennes
- Streaming, jeux vidéo, téléphonie mobile



Des exigences différentes en termes de vitesse, de fidélité pixel, de rendu perceptuel, etc.

Interface interactive — assistant de choix



Assistant de sélection de modèle SR

Facteur :

- ☐ Agrandissement 2x
- ☐ Agrandissement 3x
- ☒ Agrandissement 4x

Temps d'attente :

- ☐ Peu importe l'attente (inclut CoSeR)
- ☐ Attente raisonnable (+SwinIR)
- ☒ Résultat rapide (+RealESRGAN)
- ☐ Très rapide uniquement (ESPCN)

Préférence :

- ☐ Fluidité — fidèle à l'original, PSNR/SSIM maximal
- ☒ Détails — texture riche, LPIPS minimal
- ☐ Vitesse — meilleur PSNR parmi les plus rapides



Modèle recommandé : RealESRGAN ×4

Niveau de vitesse : Moyen (RealESRGAN — GAN, quelques minutes)

PSNR = 25.4024 dB

SSIM = 0.695977

LPIPS = 0.236081 (plus bas = meilleure qualité perceptuelle)

Modèle	PSNR (dB)	SSIM	LPIPS	Vitesse
RealESRGAN	25.4024	0.695977	0.236081	Moyen ◀ Recommandé
ESPCN	27.4041	0.749581	0.331003	Très rapide

Uploader une image et inférer

Facteur / préférence / vitesse : voir l'assistant ci-dessus

 Choisir image (0)

 Inférer

Prompt posi... Ex. : a photo of a cat (uniquement pour CoSeR)

Prompt nég... Laisser vide pour utiliser le prompt négatif par défaut de CoSeR


Démonstration — upload & inférence en un clic

Apple Watch 2 Apple Watch 2

← x4 + peu importe l'attente + détails +
prompt “alphanumeric characters”




← x4 + rapide + détails



← x4 + attente raisonnable + fluidité


Organisation des tâches

Gantt




Organisation des tâches

Gantt



Organisation des tâches

Gantt



Conclusion : apports & limites

Apports	Limites
• Cadre d'évaluation unifié et reproductible (un jeu de données, un script) • Comparaison équitable de 4 architectures fondamentalement différentes • Évaluation multi-dimensionnelle (PSNR, SSIM, LPIPS) • Outil interactif d'aide à la décision + inférence en un clic	• Un seul benchmark (Set14) — taille réduite, généralisation limitée • Dégradation purement bicubique : ne reflète pas les images réelles • Pas de mesure systématique du temps d'inférence / empreinte mémoire • CoSeR limité à une sortie native $\times 4$ (pénalisé en $\times 2$ et $\times 3$)

Conclusion : Trois messages à retenir



1

Pour l'usage

Pas un seul « meilleur modèle » :
le bon dépend du cas d'usage.

2

Pour la recherche


SwinIR domine les métriques
objectives ; CoSeR ouvre la voie
généraliste.

3


Pour la pratique

Cadre reproductible et
extensible, prêt à accueillir de
nouveaux modèles.

- [1] Juncheng Li et al. “A systematic survey of deep learning-based single-image super resolution”. In : *ACM Computing Surveys* 56.10 (2024), p. 1-40.
- [2]https://commons.wikimedia.org/wiki/File:Comparison_of_1D_and_2D_interpolation.svg
- [3] Wenzhe Shi et al. “Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, p. 1874-1883.
- [4] Xintao Wang et al. Real-ESRGAN : Training Real-World Blind Super-Resolution with Pure Synthetic Data. 2021. arXiv : 2107 . 10833 [eess.IV]. url : <https://arxiv.org/abs/2107.10833>.
- [5] Jingyun Liang et al. SwinIR : Image Restoration Using Swin Transformer. 2021. arXiv : 2108.10257 [eess.IV]. url : <https://arxiv.org/abs/2108.10257>.
- [6] Robin Rombach et al. “High-resolution image synthesis with latent diffusion models”. In : *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022, p. 10684-10695.




**LOW
RESOLUTION**



**SUPER
RESOLUTION**

LIRIS



**CENTRALE
LYON**

MERCI !