

**CENTRALE
LYON**



PAR 129
SOUTENANCE DE PROJET

Génération de musique par Apprentissage automatique

Élèves :

Joséphine BREITWILLER
Chloé HELLOCO

Tuteurs :

Alexandre SAIDI
Mohsen ARDABILIAN

Conseiller

Serge SIMOENS

Jury

Manuel COBIAN

8 avril 2025

Table des matières

Glossaire	2
1 Contexte	4
2 Introduction	4
3 État de l’art	5
3.1 Principe de fonctionnement du système	5
3.2 Représentation musicale	5
3.2.1 Représentation audio	6
3.2.2 Représentation symbolique	8
3.3 Réseau de neurones	9
3.3.1 Introduction à l’Apprentissage profond	9
3.3.2 Méthode d’apprentissage : Descente de gradient et fonctions de perte	10
3.3.3 Réseau de neurones <i>Feedforward</i>	13
3.3.4 Réseau de neurones Convolutionnels (CNN)	15
3.3.5 Réseaux Neuronaux Récurrents (RNN)	15
3.3.6 Réseaux <i>Long Short-Term Memory</i> (LSTM)	16
3.3.7 <i>Transformer</i>	17
3.3.8 BERT	19
4 Étude d’un projet de référence	19
4.1 Principe de fonctionnement	19
4.2 Entraînement et architecture du modèle	20
4.3 Structure du code	21
4.4 Résultats	21
Conclusion	21
Bibliographie	23

Glossaire

Apprentissage automatique *Machine Learning*, sous-domaine de l'intelligence artificielle qui permet à un système d'apprendre et de s'améliorer de manière autonome à l'aide des réseaux de neurones. 1–23

Apprentissage profond *Deep Learning*, sous-catégorie de l'apprentissage automatique, utilisant des réseaux de neurones à plusieurs couches pour apprendre des représentations complexes. 1, 3, 4, 9, 10, 13, 21

Descente de gradient Méthode d'optimisation utilisée pour entraîner un modèle en minimisant la fonction de perte. 1, 10–12, 14

Fonction de perte Fonction mesurant l'écart entre la sortie prédite par le modèle et la sortie attendue. 9–12, 14

IA Abréviation de *intelligence artificielle*, un domaine de l'informatique visant à simuler l'intelligence humaine à l'aide d'algorithmes. 4

LSTM *Long Short-Term Memory*, une version améliorée des RNN capable de mieux gérer les dépendances à long terme. 1, 3, 13, 16–18, 21

MIDI *Musical Instrument Digital Interface*, protocole numérique décrivant des événements musicaux tels que la note, la vitesse ou le canal. 8, 9, 15, 21

Mécanisme d'attention Méthode permettant à un modèle de se concentrer sur les parties les plus pertinentes d'une séquence d'entrée. 17, 18, 20

RNN *Recurrent Neural Network*, une architecture de réseau de neurones adaptée aux données séquentielles. 1, 3, 13, 15–18, 21

Réseau de neurones Modèle d'apprentissage inspiré du cerveau humain, composé de "neurones" interconnectés. 1, 3, 9, 10, 13, 15, 18, 21

Transformer Architecture introduite en 2017 basée sur l'attention, permettant de traiter efficacement des séquences longues en parallèle. 1, 3, 4, 13, 15, 17–19, 21

Remerciements

Nous tenons tout d'abord à remercier nos tuteurs M. Alexandre Saidi et M. Mohsen Ardabilian pour leurs conseils et leur accompagnement sur ce projet. Nous exprimons également notre gratitude envers M. Serge Simoens pour ses orientations qui nous permettent de mener au mieux la réalisation et la présentation de ce rapport.

Résumé

Le présent rapport explore un projet de recherche centré sur la génération musicale automatique à l'aide du principe d'Apprentissage profond. À travers l'étude de différents types de Réseau de neurones, tels que les RNN, LSTM et Transformer, il s'agit de comprendre comment ces architectures peuvent être utilisées pour produire des mélodies à la fois cohérentes et harmonieuses. Le projet se focalise sur l'analyse de séquences monophoniques de piano et sur l'évaluation de la qualité musicale des sorties générées. Les résultats mettent en évidence que l'intégration de motifs musicaux répétitifs améliore la perception de cohérence, en s'inspirant des structures présentes dans les compositions humaines.

This report explores a research project focused on automatic music generation using deep learning. Through the study of various types of neural networks, such as RNNs, LSTMs, and Transformer, the goal is to understand how these architectures can be leveraged to produce melodies that are both coherent and harmonious. The project focuses on the analysis of monophonic piano sequences and the evaluation of the musical quality of the generated outputs. The results highlight that incorporating repetitive musical patterns enhances the perceived coherence, drawing inspiration from structures commonly found in human compositions.

1 Contexte

Le PAr 129 est un projet de recherche qui s'inscrit dans le cadre des projets de deuxième année de l'école Centrale de Lyon. Ce projet est conduit par les autrices de ce rapport, Chloé Helloco et Joséphine Breitwiller, et encadré par les enseignants-chercheurs au laboratoire LIRIS M. Mohsen Ardabilian et M. Alexandre Saïdi, sous les conseils de M. Serge Simoens quant à la gestion de projet.

Ce rapport découle d'une alliance de notre intérêt commun pour la musique et surtout l'informatique. L'exploration de la génération musicale à travers des réseaux neuronaux représente pour nous une opportunité d'allier créativité et innovation technique, et l'opportunité de développer nos connaissances sur le sujet de l'Apprentissage profond. Si le projet a initialement exploré la génération procédurale de musique fondée sur des règles, il a progressivement évolué vers une approche plus autonome, fondée sur les principes de l'Apprentissage automatique.

Ce projet a pour premier objectif d'établir un état de l'art des techniques d'Apprentissage profond appliquées à la génération musicale automatisée. Une attention particulière est portée à l'étude approfondie des modèles de type Transformer, en mettant l'accent sur leur capacité à produire des compositions musicales d'une cohérence telles qu'elles deviennent difficilement distinguables de celles composées par des humains.

2 Introduction

La musique occupe une place centrale dans la culture humaine, et continue d'évoluer au rythme des tendances, des mouvements artistiques et des progrès technologiques. Ainsi, l'innovation technique a permis l'émergence de nouveaux courants, tels que la musique synthétique, incarnée par des artistes comme Daft Punk, qui ont exploré les sonorités électroniques et les outils numériques pour redéfinir les frontières de la création musicale.

L'avènement de l'intelligence artificielle (IA) ces dernières années a ouvert de nouvelles perspectives pour la composition musicale. Grâce aux avancées en Apprentissage automatique, des modèles d'IA sont désormais capables de générer des compositions originales, imitant parfois avec réalisme les structures mélodiques de la musique humaine.

L'émergence des réseaux neuronaux et de l'Apprentissage profond des machines depuis 2012 a marqué un tournant dans de nombreux domaines informatiques, dont la génération de musique. L'introduction des *Transformer* en 2017, une nouvelle architecture de réseau de neurones, proposée par Vaswani et al. dans l'article "Attention is All You Need", permet un traitement parallèle des séquences musicales afin d'assurer une meilleure cohérence de la musique produite et obtenir une composition plus structurée et agréable. [3]

Cependant, malgré ces progrès, la génération musicale automatique reste un défi. Les modèles d'Apprentissage profond peuvent toujours sembler insuffisants pour réussir à obtenir des compositions musicales harmonieuses, aussi riches et expressives que la composition humaine et traduisant d'une écoute sensible et émotive.

3 État de l'art

3.1 Principe de fonctionnement du système

Dans cette section, nous présenterons le principe de fonctionnement classique du système de génération musicale, fondé sur le modèle des algorithmes d'Apprentissage automatique.

Le système fonctionne à partir d'un extrait musical donné en entrée, correspondant à une courte séquence de piano monophonique. Cet extrait est analysé par la machine qui génère en sortie, selon un fonctionnement de boîte noire, une version longue de la séquence d'entrée dont il aura créé la suite, comme représenté sur la Figure 1.




FIGURE 1 – Principe de fonctionnement du système

Le cahier des charges met l'accent sur la qualité perçue par l'oreille humaine : les premiers critères d'évaluation de la piste de sortie sont l'agréabilité, la fluidité et la cohérence musicale. Afin de limiter la complexité harmonique et de se concentrer sur la génération mélodique, le système travaille sur des extraits de piano solo, sans polyphonie ni diversité instrumentale.

3.2 Représentation musicale

L'une des étapes clés de ce projet consiste à définir la forme que prennent les données soumises en entrée de la boîte noire, ainsi que celles que l'on souhaite obtenir en sortie, *i.e.* la musique générée par notre modèle.

La musique peut effectivement être représentée sous plusieurs formes, en fonction de son usage et de l'utilisateur qui l'exploite : un musicien ne choisira pas de la représenter sous la même forme qu'un ingénieur du son, par exemple. Afin de déterminer la qualité de l'apprentissage de notre boîte noire ainsi que celle de la musique générée en sortie, il est essentiel de choisir un format de représentation qui puisse être analysée, comprise et interprétée par une machine.



FIGURE 2 – Partition de l'Hymne à la joie, Beethoven [8]




FIGURE 3 – Piano roll de l'Hymne à la joie, Beethoven [5]

On définit d'abord différents **niveaux d'abstraction** de la musique, selon la complexité de son interprétation par celui qui la reçoit en fonction du degré de sensibilité musicale requis :

- **Niveau d'abstraction bas** : correspond à une compréhension simple et objective de la musique, typiquement réalisable par une machine. Il peut s'agir, par exemple, de fournir une analyse de la gamme de fréquences utilisée, de la fréquence fondamentale, du nombre de notes différentes présentes, etc.
- **Niveau d'abstraction intermédiaire** : propose une analyse plus expressive de la musique. Il permet d'identifier, par exemple, le rythme de la composition, les variations d'intensité des notes, les accents rythmiques, etc.
- **Niveau d'abstraction haut** : correspond à une écoute plus subjective, similaire à l'expérience humaine de la musique. Ce niveau pourrait inclure l'identification du genre musical, le caractère mélodieux ou agréable d'un extrait, ainsi que les émotions qu'il peut susciter.

En fonction du niveau d'abstraction souhaité, on peut extraire de ces analyses des données paramétriques (tempo, gamme de fréquences, rythme, notes utilisées...) qui permettent de caractériser la musique. À partir de ces données, il convient alors de choisir une représentation adaptée. Notre modèle priorisant la cohérence musicale, un niveau d'abstraction intermédiaire voire haut est attendu.

On distingue ainsi deux grandes catégories de représentation : la représentation audio (continue) et la représentation symbolique (discrète, basée sur un échantillonnage de la musique).

3.2.1 Représentation audio

La représentation physique de la musique, telle qu'elle est traitée par un ordinateur, un logiciel ou par des scientifiques, repose sur une analyse du signal dans le domaine temporel, fréquentiel ou encore temps-fréquence.

Ainsi, le signal peut être représenté :

- **Dans le domaine temporel** : sous la forme d'un signal audio brut 4, où l'ampli-

tude évolue en fonction du temps.

- **Dans le domaine fréquentiel** : en appliquant une transformée de Fourier, on obtient une distribution des fréquences permettant d'analyser la composition harmonique du signal musical.
- **Dans le domaine temps-fréquence** : le *spectrogramme*, voir Figure 5, permet de visualiser simultanément l'évolution des fréquences et de l'intensité sonore au fil du temps, facilitant ainsi l'identification des motifs rythmiques et harmoniques.



FIGURE 4 – Signal audio [4]




FIGURE 5 – Spectrogramme associé au signal [4]

3.2.2 Représentation symbolique

Tandis qu'un musicien utilise une représentation symbolique (par une partition ou un piano-roll, par exemple) pour modéliser sa musique, nous cherchons ici une représentation symbolique adaptée au traitement numérique de la musique par un algorithme.

Une représentation fréquemment utilisée dans ce cadre est le MIDI (*Musical Instrument Digital Interface*). Le MIDI est un protocole numérique permettant de donner des instructions de jeu à des instruments électroniques ou à des logiciels musicaux. Il permet ainsi d'algorithmer la musique, en la décrivant sous forme d'une suite d'événements musicaux.

Chaque événement MIDI se caractérise par trois paramètres principaux :

- **Numéro de canal** : numéroté de 0 à 15, il permet de distinguer différentes pistes instrumentales.
- **Numéro de note MIDI** : représentant la hauteur de la note, comprise entre 0 et 127.
- **Vélocité** : indiquant l'intensité avec laquelle la note est jouée, avec des valeurs allant de 0 à 127.

```
2, 96, Note_on, 0, 60, 90
2, 192, Note_off, 0, 60, 0
2, 192, Note_on, 0, 62, 90
2, 288, Note_off, 0, 62, 0
2, 288, Note_on, 0, 64, 90
2, 384, Note_off, 0, 64, 0
```

FIGURE 6 – Code MIDI [4]

Cette représentation, est particulièrement adaptée au traitement informatique de la musique et à l'apprentissage de la musique par une machine, du fait de la logique algorithmique qu'elle emprunte. C'est ainsi sur cette méthode de représentation MIDI que le projet va s'appuyer.

Maintenant que la forme de l'entrée et des sorties a été éclaircie, il convient de se pencher sur le principe de fonctionnement de la boîte noire : le système doit en effet être capable, à partir d'une large base de données, de procéder lui-même par auto-apprentissage à générer de la musique.

3.3 Réseau de neurones

Un réseau de neurones artificiel est un système en informatique inspiré du fonctionnement des neurones en biologie. Avec le temps, cette approche biologique s'est peu à peu transformée en une approche probabiliste. Cette section vise à en expliciter le principe et présenter les modèles les plus communément utilisés.

3.3.1 Introduction à l'Apprentissage profond

Le *deep learning* (ici noté Apprentissage profond) est une branche du *machine learning* (ici noté Apprentissage automatique) qui repose sur l'utilisation de Réseau de neurones artificiels comportant plusieurs couches. Il permet d'apprendre des représentations complexes à partir de grandes quantités de données et a révolutionné des domaines comme la reconnaissance d'images, la traduction automatique et la génération de contenu, y compris la musique.

Le principe fondamental de l'Apprentissage profond repose sur l'apprentissage d'une hiérarchie de caractéristiques directement à partir des données brutes. Contrairement aux méthodes classiques qui nécessitent une manipulation manuelle des caractéristiques, les réseaux profonds apprennent de manière automatique des représentations de plus en plus abstraites grâce à la superposition de couches neuronales. Chaque couche transforme les données en extrayant des motifs plus complexes à mesure que l'on progresse dans le réseau [10].

L'entraînement d'un réseau de neurones se fait généralement par apprentissage supervisé, une méthode où le modèle apprend à partir d'exemples annotés. Concrètement, on fournit au réseau un ensemble de données d'entraînement composé de paires (entrée, sortie attendue). Par exemple, dans le cas de la génération de musique, une entrée pourrait être un début de mélodie et la sortie attendue sa continuation. Le modèle effectue une prédiction qu'il compare à la sortie attendue, et une Fonction de perte mesure l'écart entre les deux. Un algorithme d'optimisation ajuste ensuite les poids des connexions entre neurones afin de minimiser cette erreur. Ce processus est répété sur un grand nombre d'exemples, permettant au réseau d'affiner progressivement ses prédictions et d'apprendre des relations complexes dans les données.

L'Apprentissage profond a montré des performances exceptionnelles dans les tâches où les relations et structures sous-jacentes des données sont complexes et difficiles à formaliser. Son efficacité est due à plusieurs avancées technologiques, notamment l'augmentation

des capacités de calcul, la disponibilité massive de données et des améliorations dans les architectures de réseaux neuronaux.

Dans le domaine de la génération de musique, les modèles d'Apprentissage profond sont capables d'apprendre des structures musicales et de produire des compositions originales en s'inspirant d'un corpus de pièces existantes. L'auto-apprentissage musical se fonde ainsi sur l'extraction et la hiérarchisation de paramètres (notes, tempo, durée, gamme, hauteur...).

3.3.2 Méthode d'apprentissage : Descente de gradient et fonctions de perte

L'apprentissage des Réseau de neurones repose sur l'optimisation d'une Fonction de perte qui mesure l'écart entre les prédictions du modèle auto-apprenant et les valeurs attendues - les séquences musicales, dans notre cas. Pour minimiser cette perte, on utilise un algorithme fondamental en Apprentissage profond : la Descente de gradient.

Descente de gradient

La Descente de gradient est une méthode qui permet d'ajuster les paramètres du réseau neuronal pour réduire l'erreur. L'idée est de modifier progressivement les poids du modèle dans la direction opposée à l'erreur, afin de la diminuer. :

$$W \leftarrow W - \eta \frac{\partial \mathcal{L}}{\partial W} \quad (1)$$

où :

- W représente les poids du réseau ;
- $\mathcal{L}$ est la Fonction de perte ;
- η est le taux d'apprentissage (*learning rate*) qui contrôle l'amplitude des mises à jour.

Pour mieux comprendre ce processus, on peut l'imaginer comme une recherche d'un minimum dans un espace en plusieurs dimensions. Le gradient montre la direction où l'erreur est la plus grande, et l'algorithme ajuste les poids dans la direction opposée pour réduire cette erreur. On peut visualiser cela dans un espace à trois dimensions, où chaque point représente un ensemble de poids. L'algorithme commence à un point donné et se déplace dans l'espace pour trouver la position qui minimise l'erreur, comme s'il descendait une pente.

Gradient Descent




FIGURE 7 – Illustration en 2D de la méthode du gradient descendant

Il existe plusieurs variantes de la Descente de gradient :

- **Descente de gradient standard (Batch Gradient Descent)** : mise à jour après avoir traité l'ensemble des données d'entraînement ;
- **Descente de gradient stochastique (SGD - Stochastic Gradient Descent)** : mise à jour après chaque échantillon, ce qui introduit plus de bruit mais accélère l'apprentissage ;
- **Descente de gradient mini-batch** : mise à jour après avoir vu un sous-ensemble de données, combinant stabilité et rapidité.

Fonctions de perte

La Fonction de perte est un élément clé de l'apprentissage car elle guide l'optimisation [7]. Selon la tâche, différentes fonctions de perte sont utilisées :

Erreur quadratique moyenne (MSE – Mean Squared Error) Couramment utilisée pour les tâches de régression, la MSE pénalise davantage les grandes erreurs, ce qui la rend particulièrement sensible aux valeurs aberrantes.

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2)$$

où :

- y_i est la valeur réelle ;
- $\hat{y}_i$ est la valeur prédite.

Entropie croisée (Cross-Entropy) Principalement utilisée pour les tâches de classification, la fonction d'entropie croisée mesure la distance entre la distribution prédite et la distribution réelle des classes.

$$\mathcal{L}_{\text{CE}} = - \sum_i y_i \log(\hat{y}_i) \quad (3)$$

Cette fonction est généralement combinée à une activation softmax pour transformer les sorties du modèle en probabilités.

Les fonctions *Softmax* pour la génération musicale

Dans le cadre de la génération musicale, on utilise des variantes de l'entropie croisée adaptées aux séquences, notamment l'application de *Softmax* tempérée pour la modélisation des notes et accords.

***Softmax* standard** La fonction *softmax* transforme un vecteur de scores en une distribution de probabilité :

$$\hat{y}_i = \frac{\exp(x_i)}{\sum_j \exp(x_j)} \quad (4)$$

où x_i représente le score brut assigné à la classe i . Cette fonction est utilisée pour prédire la probabilité de chaque note ou accord suivant dans une séquence musicale.

***Softmax* tempérée** Dans certains modèles, notamment ceux utilisés pour la musique symbolique, une variante appelée *Softmax* Tempérée permet de contrôler la diversité des prédictions en introduisant un paramètre de température T :

$$\hat{y}_i = \frac{\exp(x_i/T)}{\sum_j \exp(x_j/T)} \quad (5)$$

où :

- $T > 1$ favorise des prédictions plus uniformes (plus de diversité) ;
- $T < 1$ accentue les différences entre les probabilités et force le modèle à choisir les classes les plus probables.

Ce mécanisme est essentiel en génération musicale car il permet d'ajuster le niveau de créativité du modèle. La modulation de la température aide à éviter une sur-généralisation des structures musicales et encourage la variété des motifs.

Bilan

L'optimisation d'un réseau de neurones repose sur la Descente de gradient et le choix d'une Fonction de perte adaptée à la tâche cible. Dans le cas de la génération musicale, l'entropie croisée avec une activation *softmax* joue un rôle clé. L'ajustement de la température permet de moduler la diversité des morceaux générés, assurant un équilibre entre cohérence et créativité.




FIGURE 8 – Illustration de l'utilisation du softmax pour le calcul d'entropie croisée [4]

Le *Apprentissage profond* repose sur plusieurs architectures de Réseau de neurones adaptées à des tâches spécifiques. Parmi les plus utilisées, on retrouve les Réseau de neurones convolutionnels (CNN), les Réseau de neurones récurrents (RNN) et leurs variantes comme les LSTM, ainsi que les *Transformer*, particulièrement performants pour la modélisation de séquences comme le langage naturel ou la musique.

Avant d'explorer des architectures plus avancées comme les CNN et les *Transformer* qui vont être présenté dans la suite, il est essentiel de comprendre les Réseau de neurones les plus simples : les Réseau de neurones *Feedforward*.

3.3.3 Réseau de neurones *Feedforward*




FIGURE 9 – Illustration d'un réseau de neurones *Feedforward* [4]

Structure d'un Réseau *Feedforward* Un réseau de neurones *Feedforward* est composé de plusieurs couches successives de neurones où l'information circule uniquement

dans une direction, de l'entrée vers la sortie, sans boucles ni rétroactions. Il se compose généralement de :

- **Une couche d'entrée** : reçoit les données brutes sous forme d'un vecteur de caractéristiques ;
- **Une ou plusieurs couches cachées** : effectuent des transformations non linéaires grâce aux poids synaptiques et aux fonctions d'activation ;
- **Une couche de sortie** : génère le résultat final du réseau.

La sortie de chaque neurone d'une couche est transmise aux neurones de la couche suivante selon l'équation suivante :

$$h_i = f \left(\sum_j W_{ij} x_j + b_i \right), \quad (6)$$

où :

- x_j représente les entrées de la couche précédente ;
- W_{ij} sont les poids des connexions entre les neurones ;
- b_i est un biais ajouté pour améliorer la flexibilité du modèle ;
- f est une **fonction d'activation**, souvent une fonction non linéaire comme la ReLU :

$$f(x) = \max(0, x). \quad (7)$$

Entraînement d'un Réseau *Feedforward* L'entraînement d'un réseau *Feedforward* repose sur l'algorithme de Descente de gradient, qui ajuste les poids pour minimiser une Fonction de perte $\mathcal{L}$ (par exemple, l'erreur quadratique moyenne pour la régression ou l'entropie croisée pour la classification). Ce processus repose sur :

- Le calcul de la **perte** entre la sortie prédite et la sortie réelle ;
- L'utilisation de **rétropropagation** pour calculer le gradient des poids par rapport à la perte ;
- La mise à jour des poids avec l'algorithme de **descente de gradient stochastique** (SGD) :

$$W_{ij} \leftarrow W_{ij} - \eta \frac{\partial \mathcal{L}}{\partial W_{ij}}, \quad (8)$$

où η est le taux d'apprentissage.

Limites des Réseaux *Feedforward* Bien que les réseaux *Feedforward* soient puissants, ils présentent certaines limites :

- Ils ne tiennent pas compte des relations **spatiales** (dans les images) ni **temporelles** (dans les séquences musicales) ;
- Ils nécessitent un grand nombre de paramètres, ce qui peut entraîner un surapprentissage (*overfitting*).

C'est pourquoi des architectures spécialisées, comme les CNN pour les images et les RNN ou *Transformer* pour les séquences, ont été développées.

3.3.4 Réseau de neurones Convolutionnels (CNN)

Les CNN (*Convolutional Neural Networks*) sont principalement utilisés pour le traitement des données spatiales, comme les images ou les spectrogrammes audio. Leur structure repose sur :

- **Les couches de convolution**, qui appliquent des filtres pour extraire des motifs locaux (bords, textures, formes) ;
- **Les couches de pooling**, qui réduisent la dimensionnalité des données tout en préservant les informations essentielles.

Les CNN sont peu adaptés aux données séquentielles comme le texte ou la musique sous forme symbolique (MIDI), car ils ne capturent pas naturellement la dépendance temporelle entre les éléments d'une séquence.

3.3.5 Réseaux Neuraux Récurrents (RNN)

Les RNN (*Recurrent Neural Networks*) sont conçus pour traiter les données séquentielles. Contrairement aux CNN, ils possèdent une **mémoire interne** qui leur permet de conserver un état dépendant des entrées précédentes. Leur fonctionnement repose sur une boucle récurrente où, à chaque étape t , l'état caché h_t est mis à jour comme suit :

$$h_t = f(W_h h_{t-1} + W_x x_t + b), \quad (9)$$

où x_t est l'entrée courante, W_h et W_x sont les matrices de poids, et b est un biais.




FIGURE 10 – Illustration du fonctionnement d'un réseau de neurones récurrents [4]

Cependant, les RNN souffrent du problème du gradient évanescent, qui rend difficile l'apprentissage de dépendances longues dans les séquences [9].

3.3.6 Réseaux *Long Short-Term Memory* (LSTM)

Pour pallier ces limitations, les LSTM (*Long Short-Term Memory*) ont été introduits. Ce sont des RNN améliorés intégrant des cellules mémoire et trois portes qui régulent le flux d'information [6] :

- **Porte d'oubli** : décide quelles informations de l'état précédent doivent être oubliées.
- **Porte d'entrée** : contrôle quelles nouvelles informations sont ajoutées à la mémoire.
- **Porte de sortie** : génère l'état caché de la cellule pour l'étape suivante.




FIGURE 11 – Illustration du fonctionnement d'un réseau LSTM

Le fonctionnement d'une cellule LSTM est défini par les équations suivantes :

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (\text{Porte d'oubli}) \quad (10)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (\text{Porte d'entrée}) \quad (11)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (\text{État candidat}) \quad (12)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (\text{Mise à jour de la mémoire}) \quad (13)$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (\text{Porte de sortie}) \quad (14)$$

$$h_t = o_t \odot \tanh(C_t) \quad (\text{Nouvel état caché}) \quad (15)$$

Ces mécanismes permettent aux LSTM de mieux capturer les dépendances longues, ce qui les rend utiles pour la génération de séquences musicales.

3.3.7 Transformer

Présentation du principe générale Les *Transformer* sont aujourd'hui la référence pour le traitement des séquences longues (texte, musique, audio). Introduits par Vaswani et al. en 2017 avec le célèbre article "Attention is All You Need", ils ont remplacé les RNN et LSTM dans de nombreux domaines. Contrairement à ces derniers qui traitent les séquences de manière séquentielle, les *Transformer* utilisent un mécanisme d' **Attention** qui leur permet de traiter toutes les positions d'une séquence simultanément. Le principe de l'Mécanisme d'attention est le suivant :

- **Le Self-Attention (auto-attention)** : Chaque élément de la séquence pèse l'importance des autres éléments, ce qui permet de modéliser les relations longues distances de manière efficace.
- **Les matrices de poids** : Les poids d'Mécanisme d'attention dans un *Transformer* sont les coefficients qui déterminent à quel point chaque élément d'une séquence doit influencer les autres éléments. Ils sont calculées lors de l'entraînement des cellules de self attention. Ainsi ils déterminent quelles parties de la séquence sont les plus pertinentes pour prédire le prochain élément. Pour de longues séquences ces matrices sont très importantes ce qui implique que l'entraînement des transformers demande un calcul de beaucoup de données.

Architecture d'un Transformer Un *Transformer* est composé de deux parties principales :

- **L'encodeur** : transforme l'entrée en une représentation contextuelle.
- **Le décodeur** : génère la sortie en tenant compte des représentations de l'encodeur. Chaque couche d'encodeur et de décodeur contient :

- Un mécanisme d' **auto attention** qui permet au modèle de peser l'importance de chaque élément de la séquence. L'auto-attention simple est étendue avec plusieurs têtes d'Mécanisme d'attention indépendantes. Cela permet au modèle de capturer différents types de relations entre les éléments de la séquence.
- Une couche de **normalisation et feedforward**, qui applique des transformations non linéaires pour améliorer l'expressivité du modèle.

Le Mécanisme d'auto-attention Le **self-attention** (ici auto-attention) est au cœur du *Transformer*. Il consiste à calculer une pondération entre chaque mot (ou note) d'une séquence et tous les autres. Pour une séquence d'entrée X , on calcule trois matrices :

- **Matrice des clés** K (Key),
- **Matrice des requêtes** Q (Query),
- **Matrice des valeurs** V (Value).

L'Mécanisme d'attention est alors obtenue via :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V. \quad (16)$$

Ce mécanisme permet au modèle de capturer les relations complexes entre les éléments d'une séquence.

Type	Adapté aux séquences ?	Avantages	Inconvénients
CNN	Non	Très efficace pour l'analyse visuelle (ex. images, spectrogrammes)	Ne capture pas la dépendance temporelle entre les éléments d'une séquence
RNN	Oui	Capable de traiter des séquences en capturant les relations temporelles	Problème du gradient évanescant, difficulté à apprendre sur de longues séquences
LSTM	Oui (meilleur que RNN)	Mémoire longue durée grâce aux portes de contrôle, améliore les performances sur les longues séquences	Coût de calcul élevé, entraînement plus long que les RNN classiques
Transformer	Oui	Traitement parallèle efficace, capture des dépendances longues distances grâce au self-attention	Très gourmand en calcul et en mémoire, nécessité de grandes quantités de données pour un bon apprentissage

TABLE 1 – Comparaison des différentes architectures de Réseau de neurones.

Comparaison des architectures Les premiers projets de génération musicale avec utilisation de *Transformer* permettent d'obtenir des compositions variées, mais la prin-

La principale difficulté reste d'intégrer la cohérence de la mélodie pour être agréable à l'oreille humaine. Il convient ainsi d'établir une nouvelle stratégie pour inclure ce critère. Un modèle développé de génération musicale par *Transformer* sera étudié plus loin.

3.3.8 BERT

Pour apporter une simplification au modèle complexe des *Transformer*, il en existe une version simplifiée, appelée BERT (*Bidirectional Encoder Representations from Transformer*). Le principe du fonctionnement du BERT s'appuie celui d'un *Transformer*, en n'utilisant que sa partie "encodeur". Dans notre projet, nous avons adapté le système de BERT au contexte musical. Le modèle est ainsi conçu pour recevoir deux segments distincts en entrée, et apprendre à modéliser leurs relations structurelles.

Une première tâche d'auto-apprentissage consiste en le masquage partiel de séquences (*Masked Language Modeling*). Une ou plusieurs notes sont remplacées par un token spécial de type [MASK]. Le modèle est ensuite entraîné à prédire les éléments manquants à partir du contexte musical fourni, aussi bien en amont qu'en aval du masque.

La seconde tâche est celle de la prédiction, appelée *Next Sentence Prediction*, qui consiste à déterminer si deux segments musicaux fournis successivement en entrée appartiennent bien à une même continuité (par exemple une progression logique dans une œuvre musicale), ou s'ils ont été sélectionnés aléatoirement et sont indépendants. Cette tâche permet au modèle d'acquérir une forme de sens musical, en apprenant à reconnaître les transitions naturelles et cohérentes entre deux segments.

Le modèle du BERT présente une simplification d'implémentation intéressante par rapport au système complexe des *Transformer*, par sa structure d'encodeur seul.

4 Étude d'un projet de référence

Dans le cadre de notre projet de recherche, nous nous sommes penchées plus en détails sur le papier d'une équipe de chercheurs : Shih, Y.-J., Wu, S.-L., Zalkow, F., Müller, M., Yang, Y.-H. (2022). *Theme Transformer : Symbolic Music Generation With Theme-Conditioned Transformer*. IEEE Transactions on Multimedia. Nous détaillons dans cette section leurs travaux [11] [1] [2].

4.1 Principe de fonctionnement

Si les premiers projets de génération musicale permettent d'obtenir du contenu musical plus ou moins complexe, la principale difficulté que rencontrent ces programmes sont la complexité de faire intégrer à la machine la cohérence et l'agréabilité de la mélodie, critères subjectifs qui semblent relever de l'écoute humaine (niveau d'abstraction haut).

Ainsi, le système étudié cherche à assurer cette cohérence musicale en prenant en compte dans son fonctionnement l'idée de la répétition d'un motif musical dans la bande son générée (analogiquement au refrain dans la chanson). La répétition du motif permet ainsi, par imitation à la composition humaine de musique, de créer un effet 'mémorable' pour l'auditeur et donc de permettre une meilleure cohérence. Le modèle impose donc

la règle de répétition du motif, et guide ainsi le *transformer* dans la génération de la musique.

4.2 Entraînement et architecture du modèle

L'apprentissage du modèle repose sur une base de données de compositions existantes, à partir desquelles il extrait et analyse des motifs récurrents. L'entraînement est conçu pour permettre au *Transformer* de comprendre la structure musicale et de générer des séquences respectant les règles d'harmonie et de mélodie.

L'architecture suit un schéma à double mémoire :

L'encodeur traite le thème fourni en entrée et en extrait les caractéristiques essentielles à l'aide d'un mécanisme d'attention croisée (cross-attention). Le décodeur génère la musique en s'appuyant sur les informations du thème, en utilisant l'auto-attention (self-attention) pour assurer une cohérence dans la séquence produite. Cette architecture, Figure 12, permet au modèle de reproduire la structure d'une composition musicale tout en ajoutant des variations naturelles, essentielles pour éviter un rendu mécanique ou répétitif.




FIGURE 12 – Principe du système à double mémoire [2]

4.3 Structure du code

Le projet de référence est organisé autour d'un dépôt GitHub [1] structuré en plusieurs modules :

Base de données des thèmes : Un ensemble de fichiers MIDI contenant les extraits utilisés pour conditionner le modèle. **Modèle entraîné :** Une version pré-entraînée du *Transformer*, prête à être exploitée pour générer de nouvelles séquences.

Scripts Python principaux :

- *train.py* : Script permettant d'entraîner le modèle sur des données musicales.
- *inference.py* : Permet d'utiliser le modèle entraîné pour générer des nouvelles compositions à partir d'un thème donné.
- *myTransformer.py* : Implémente l'architecture spécifique du *Transformer* pour la génération musicale.
- *mymodel.py* : Définit le modèle de génération en intégrant le conditionnement thématique.

4.4 Résultats

La méthode mise en place dans ce système permet d'obtenir des séquences complètes à partir de courts thèmes musicaux. Les extraits ainsi générés par la machine sont disponibles à l'écoute [2] et témoignent d'une bonne qualité. On observe sur la Figure 13 la visualisation du piano roll d'un extrait obtenu, avec en rose le thème répété.




FIGURE 13 – Piano roll des résultats générés [2]

Conclusion

Ce projet de recherche explore le potentiel des Réseau de neurones pour la génération musicale, en mettant particulièrement l'accent sur les architectures de Apprentissage profond comme les RNN, LSTM et *Transformer*.

La génération de musique par les machines présentent notamment des enjeux concernant les critères d'agréabilité de la musique pour l'oreille humaine. Ainsi, une approche adoptée consiste à développer un modèle basé sur les *Transformer*, en intégrant une représentation symbolique de la musique (MIDI) et en intégrant une règle de répétition d'un thème musical, par imitation à la composition de musique manuelle. La suite du

projet consisterait à affiner notre modèle, à explorer l'utilisation des architectures BERT et à comparer leurs performances afin d'améliorer la fluidité et la richesse musicale des morceaux générés.

Bibliographie

- [1] ATO SYSTEM. *Theme Transformer : Official GitHub Repository*. Disponible sur GitHub. Consulté le 6 février 2025. 2022. URL : <https://github.com/atosystem/ThemeTransformer>.
- [2] ATO SYSTEM. *Theme Transformer : Project Website*. Disponible en ligne. Consulté le 6 février 2025. 2022. URL : <https://atosystem.github.io/blogs/theme-transformer>.
- [3] Jean-Pierre BRIOT. *Support à l'Entretien filmé sur Informatique et Musique au LIP6*. HAL Id : hal-04709249. 2024. URL : <https://hal.archives-ouvertes.fr/hal-04709249>.
- [4] Jean-Pierre BRIOT, Gaëtan HADJERES et François PACHET. "Deep Learning Techniques for Music Generation - A Survey". In : *ArXiv abs/1709.01620* (2017). URL : <https://api.semanticscholar.org/CorpusID:12211154>.
- [5] Sam DHANASEKARAN. *Creating Ode to Joy in FL Studio*. 2023. URL : https://www.youtube.com/watch?v=3b_6NoIxETQ.
- [6] S. HOCHREITER et J. SCHMIDHUBER. "Long Short-Term Memory". In : *Neural Computation* 9.8 (nov. 1997), p. 1735-1780. ISSN : 0899-7667, 1530-888X. DOI : 10.1162/neco.1997.9.8.1735. URL : <https://direct.mit.edu/neco/article/9/8/1735-1780/6109>.
- [7] Wenkai HUANG et al. "Hyperbolic Music Transformer for Structured Music Generation". In : *IEEE Transactions on Multimedia* (2024). Corresponding author : Yu Wu (wuyu8320@gzhu.edu.cn).
- [8] IMUSIC SCHOOL. *Cours de musique en ligne*. 2024. URL : <https://www.imusicschool.com>.
- [9] Y. LECUN et al. "Gradient-based learning applied to document recognition". In : *Proceedings of the IEEE* 86.11 (nov. 1998), p. 2278-2324. ISSN : 1558-2256. DOI : 10.1109/5.726791.
- [10] S. RISI et J. TOGELIUS. "Increasing Generality in Machine Learning through Procedural Content Generation". In : *arXiv* (mars 2020). arXiv :1911.13071 [cs]. URL : <http://arxiv.org/abs/1911.13071>.
- [11] Yi-Jen SHIH et al. "Theme Transformer : Symbolic Music Generation with Theme-Conditioned Transformer". In : *IEEE Transactions on Multimedia* 24 (2022), p. 2345-2357. DOI : 10.1109/TMM.2022.3147891. URL : <https://arxiv.org/pdf/2111.04093>.