

**CENTRALE
LYON**

UE PRO
PROJET APPLICATION - RECHERCHE

La génération de contenu procédurale

Élèves :
Jincheng HUANG
Rongxin LI

Enseignants :
Mohsen ARDABILIAN
Alexandre SAIDI

Conseiller :
Manuel COBIAN

21 avril 2026

Table des matières

Introduction	2
1 Introduction	2
2 Contexte	2
2.1 Rappel des projets précédants	2
2.2 Objectif	3
3 État de l'art	4
3.1 Génération de contenu procédural	4
3.2 Définition de la super-résolution	4
3.3 Méthodes classiques	6
3.4 Méthodes basées sur l'apprentissage profond	7
3.4.1 Méthodes d'upsampling	7
3.4.2 Optimisation des paramètres	8
3.5 Méthodes avancées récentes	9
3.6 Limites et perspectives	10
4 Comparaison des modèles de super-résolution	11
4.1 Modèles principaux étudiés	11
4.1.1 ESPCN	11
4.1.2 Real-ESRGAN	12
4.1.3 SwinIR	12
4.1.4 Difussion upscale	13
4.1.5 Réseau CoSeR	14
4.2 Protocole expérimental	15
4.2.1 Jeu de données et configuration générale	15
4.2.2 Conditions d'inférence et principe de comparaison	16
4.2.3 Détails techniques des modèles comparés	16
4.3 Comparaison quantitative des résultats	18
4.3.1 Méthodes d'évaluation utilisées	18
4.3.2 Analyse des différents modèles	19
4.4 Comparaison qualitative des résultats	21
4.5 Synthèse et applications pour la super-résolution	24
5 Interface interactive et démonstration d'usage	25
5.1 Assistant de recommandation de modèle	25
5.2 Inférence sur image personnalisée	26
5.3 Cas particulier du modèle CoSeR	27
5.4 Exemples de résultats générés	27
5.5 Intérêt de l'interface dans le cadre du projet	28
6 Organisation des tâches	28
Conclusion	31
Bibliographie	33

Introduction

1 Introduction

La génération de contenu procédural (PCG) permet de produire à grande échelle des textures et images pour les jeux, la simulation et la création numérique, mais elle s'appuie souvent sur des contenus de résolution limitée afin de réduire les coûts de calcul, de stockage et de rendu.

Dans ce contexte, la super-résolution (SR) vise à reconstruire, à partir d'une image basse résolution (LR), une version haute résolution (HR) plus nette et plus détaillée, tout en respectant la cohérence structurelle de la scène ; ce problème inverse étant intrinsèquement mal posé, les méthodes récentes doivent arbitrer entre fidélité de reconstruction, qualité perceptive et coût de calcul. Ce projet étudie l'intégration de la SR dans une chaîne PCG et compare plusieurs familles de modèles représentatives (interpolation bicubique comme baseline, modèles d'apprentissage profond de type GAN/Transformer/diffusion) afin d'identifier, pour des contenus orientés textures, les compromis les plus pertinents en termes de rendu visuel, d'artefacts et de robustesse.

2 Contexte

2.1 Rappel des projets précédants

La génération de contenu procédurale (Procedural Content Generation, PCG) constitue un axe de recherche récurrent au sein des projets PAr menés au laboratoire LIRIS depuis plusieurs années. Les travaux précédents ont progressivement exploré différentes modalités, méthodes et niveaux de complexité, formant une continuité scientifique cohérente.

En 2022, le projet s'est concentré sur la création d'un générateur de niveaux pour un jeu vidéo. L'objectif principal était de produire automatiquement des cartes jouables à l'aide de règles procédurales, posant ainsi les bases de la génération algorithmique de contenu.

En 2023, l'axe de recherche a évolué vers une approche multimodale, en étudiant la relation entre musique, émotions et génération d'images. Ce projet introduisait l'espace émotionnel Valence-Arousal afin de relier des signaux musicaux à des représentations visuelles, marquant une intégration de notions sémantiques dans la PCG.




FIGURE 1 – Schéma récapitulatif du projet 2023.

En 2024, les travaux ont approfondi les aspects techniques de la génération visuelle à partir de peu d'exemples. Une approche hybride combinant VQ-VAE et Wave Function Collapse (WFC) a été proposée afin de générer des motifs complexes et diversifiés tout en conservant une forte cohérence structurelle.




FIGURE 2 – Image originale et image reconstruite dans le projet 2024.

Ces projets successifs ont permis de mettre en évidence les limites des approches purement locales ou strictement basées sur la reconstruction pixelique. Ils ouvrent naturellement la voie à des méthodes intégrant des modèles génératifs avancés et une compréhension plus globale du contenu, ce qui constitue le point de départ du présent projet.

2.2 Objectif

Dans un contexte de développement rapide des technologies d'infographie et d'intelligence artificielle, la génération procédurale de contenu (PCG) est devenue un moyen essentiel de production de contenu numérique. Ce contenu comprend des images, des textures, des scènes et des modèles 3D, largement utilisés dans le développement de jeux vidéo, la réalité virtuelle, la production cinématographique et télévisuelle, ainsi que l'art numérique.

Cependant, l'expansion continue de la PCG dans les applications pratiques a fait émerger un problème majeur : la qualité visuelle du contenu généré est souvent limitée, malgré la recherche d'une grande efficacité et d'une génération à grande échelle. En raison des contraintes liées aux ressources de calcul, à l'espace de stockage et à la complexité des algorithmes de génération, les systèmes de PCG privilégient généralement la génération d'images basse ou moyenne résolution, ce qui affecte le rendu visuel final et l'expérience utilisateur.

Par conséquent, améliorer la qualité d'image sans augmenter significativement les coûts de génération est devenu un enjeu crucial à résoudre d'urgence dans le domaine de la PCG. La technologie de super-résolution vise à reconstruire des images haute résolution à partir d'images basse résolution, offrant ainsi une solution efficace pour améliorer la qualité visuelle en restaurant les détails et en renforçant la netteté. Ces dernières années, grâce au développement des méthodes d'apprentissage profond, la super-résolution a considérablement progressé en termes de précision de reconstruction et de qualité visuelle.

Pour ces raisons, ce projet axe ses recherches sur la super-résolution d'images dans le cadre de la génération procédurale de contenu. En combinant la technologie SR au processus de génération PCG, la qualité d'image peut être nettement améliorée tout en préservant l'efficacité de la génération, ce qui accroît l'utilisabilité et le réalisme du contenu généré.

3 État de l'art

Ce chapitre présente les concepts et méthodes nécessaires à ce travail. Nous introduisons d'abord la génération de contenu procédural, puis nous définissons la super-résolution comme un problème inverse visant à reconstruire une image haute résolution à partir d'une observation dégradée. Nous passons ensuite en revue les approches classiques, avant de détailler les méthodes basées sur l'apprentissage profond, en mettant l'accent sur les stratégies d'upsampling et les choix d'optimisation (fonctions de perte, compromis fidélité-perception). Enfin, nous synthétisons les avancées récentes et discutons les limites et perspectives afin de motiver les orientations retenues pour la suite.

3.1 Génération de contenu procédural

Dans le domaine de l'informatique, la génération de contenu procédurale (PCG) désigne la création automatisée de contenus numériques tels que des textures, des niveaux de jeux, des modèles 3D, des animations ou des images, en respectant un ensemble de contraintes et de règles prédéfinies. Cette thématique, essentielle pour des applications variées comme le cinéma, les jeux vidéo, la simulation et la planification territoriale, a une longue histoire marquée par une évolution constante.

Historiquement, les méthodes de PCG reposaient sur des approches basées sur la recherche, les solveurs, les règles et les grammaires. Cependant, depuis plus d'une décennie, le domaine s'est enrichi avec l'intégration de l'intelligence artificielle (IA).

3.2 Définition de la super-résolution

La super-résolution d'image (SR) désigne l'ensemble des méthodes visant à reconstruire/produire une image haute résolution (HR) à partir d'une image basse résolution (LR) correspondante, afin d'augmenter la résolution spatiale et de restaurer des détails (textures, contours) dégradés par l'acquisition ou le traitement. Historiquement, l'idée a d'abord été mobilisée pour dépasser certaines limites physiques de résolution, puis, dans le contexte de la vision par ordinateur, elle s'est imposée comme un procédé consistant à générer des images HR depuis des images LR.




FIGURE 3 – Le SISR vise à reconstruire une image haute résolution (HR) à partir d’une image basse résolution (LR) dégradée.

Selon la source d’information disponible, on distingue notamment : la single-image super-resolution (SISR cf. Figure 3) : SR à partir d’une seule image LR, les approches multi-images (Kawulok et al., 2020 [7]) et la video super-resolution, exploitant les relations entre images successives (Liu et al., 2020b [12]).

Du point de vue du problème inverse, on suppose que l’image LR résulte d’un processus de dégradation appliqué à une image HR : sous-échantillonnage, flou, bruit, etc. Dans ce cadre, la SR cherche à apprendre une fonction de reconstruction qui approxime l’inverse de cette dégradation. La structure globale de super-résolution est présentée dans la figure 4.




FIGURE 4 – La structure globale de super-résolution

L’image basse résolution peut être modélisée comme :

$$I_x^{LR} = d(I_y^{HR}; \theta) . \quad (1)$$

où d est la fonction de dégradation, I_y^{HR} est l’image HR de référence, et θ regroupe les paramètres de dégradation (typiquement facteur d’échelle, type de flou, bruit).

En pratique, le processus de dégradation et ses paramètres sont souvent inconnus, et l’on ne dispose que de LR pour estimer HR.

La SR vise à estimer une fonction g qui approxime l’inverse de d :

$$\hat{I}_y^{HR} = I_y^E = g(I_x^{LR}; \theta) \approx d^{-1}(I_x^{LR}) . \quad (2)$$

Le problème est dit ill-posed car g n'est pas injective : il existe potentiellement une infinité de I_y^E satisfaisant $d(I_y^E; \theta) = I_x^{LR}$. Plusieurs images HR distinctes peuvent conduire à une LR très similaire après dégradation (processus “many-to-one”), ce qui rend la reconstruction intrinsèquement ambiguë et nécessite l'introduction d'a priori, de régularisation, ou de stratégies d'apprentissage adaptées.

Dans le cas général, la dégradation simplifiée est souvent utilisée avec un seul opérateur de sous-échantillonnage, fréquemment bicubique :

$$d(I_y^{HR}; \theta) = I_y^{HR} \downarrow_{sf}, \quad (3)$$

où $\downarrow_{sf}$ est le facteur d'échelle.

Dans certaines études, comme (Zhang, Zuo et Zhang, 2018 [28]), les chercheurs ont utilisé davantage d'opérations dans la fonction de sous-échantillonnage, et l'opération globale de sous-échantillonnage est la suivante :

$$d(I_y^{HR}; \theta) = (I_y^{HR} * j) \downarrow_{sf} + n_r, \quad (4)$$

avec j noyau de flou et n_r bruit (p. ex. gaussien).

Le but est de minimiser une fonction de perte entre l'HR estimée et l'HR référence (quand elle existe), éventuellement avec un terme de régularisation :

$$\hat{f} = \arg \min_f \mathcal{L}(I_y^E, I_y^{HR}) + h \phi(f), \quad (5)$$

où $\mathcal{L}$ peut être une perte pixel-wise comme la MSE, h est un poids d'équilibre, et ϕ un terme de régularisation/contraintes.

3.3 Méthodes classiques

Avant l'avènement de l'apprentissage profond, la super-résolution d'images reposait principalement sur les méthodes classiques de traitement d'images. Selon leurs principes de modélisation, ces méthodes se divisent généralement en quatre catégories : méthodes basées sur le domaine fréquentiel, méthodes d'interpolation, méthodes de reconstruction par régularisation ou contraintes, et méthodes d'apprentissage (Tian & Ma, 2011 [24]).

Les méthodes d'interpolation génèrent une image haute résolution par estimation des pixels d'une image basse résolution, telles que l'interpolation au plus proche voisin, bilinéaire et bicubique (Gonzalez et al., 2008 [5]). Simples et rapides, elles ne permettent toutefois pas de restaurer efficacement les détails haute fréquence, ce qui entraîne souvent des images floues (Qureshi et al., 2012 [17]).

Les méthodes fréquentielles exploitent les relations spectrales entre plusieurs images basse résolution afin de reconstruire les composantes haute fréquence, en utilisant notamment les décalages subpixeliques entre images (Park et al., 2003 [14]). Bien qu'efficaces et peu coûteuses en calcul, elles reposent sur des hypothèses restrictives limitant leur robustesse en conditions réelles (Wheeler, 2007 [26]).

Les méthodes par régularisation ou contraintes formulent la super-résolution comme un problème inverse, intégrant des connaissances a priori pour stabiliser la reconstruction. Parmi les approches représentatives figurent la rétroprojection itérative (Irani et Peleg, 1991 [6]) et la projection sur ensembles convexes (Patti et Tekalp, 1997 [15]).

Enfin, les méthodes d'apprentissage apprennent la relation entre patches basse et haute résolution à partir de données d'entraînement, parmi lesquelles les méthodes basées sur la représentation parcimonieuse constituent des travaux emblématiques (Yang et al., 2010 [27]).

Ces approches classiques ont établi les fondements de la super-résolution, mais leurs limites en termes de restitution des détails et de robustesse ont motivé le développement ultérieur des méthodes basées sur l'apprentissage profond.

3.4 Méthodes basées sur l'apprentissage profond

La nature « ill-posed » explique la transition progressive des approches fondées sur des a priori explicites vers des méthodes d'apprentissage profond, capables d'intégrer dans un même modèle l'extraction de caractéristiques, le mapping non linéaire et la reconstruction finale. Au fil des ans, de nombreuses approches d'apprentissage profond ont été développées dans le milieu universitaire pour relever le défi de la super-résolution. Bien que les modèles de super-résolution supervisés présentent des variations importantes et puissent être classés en fonction de composants tels que la méthode de suréchantillonnage utilisée, l'architecture du réseau d'apprentissage profond, l'algorithme d'apprentissage et le cadre du modèle, tous les modèles de super-résolution d'images supervisés sont fondamentalement basés sur des combinaisons de ces composants.

3.4.1 Méthodes d'upsampling

L'objectif du SISR est d'agrandir les images de petite taille tout en préservant autant que possible leur précision. Par conséquent, l'opération d'agrandissement (également appelée suréchantillonnage) constitue une étape cruciale du SISR. Les mécanismes d'upsampling actuels peuvent être classés en quatre types : SR pré-upsampling, SR post-upsampling, SR progressive upsampling et SR itératif up/downsampling. Cette section présente plusieurs méthodes d'upsampling qui prennent en charge ces mécanismes.

Les méthodes DL-SR évitent de se limiter à une interpolation fixe, qui n'ajoute pas d'information et tend à lisser textures et contours. Elles privilégient des modules d'upsampling apprenables, dont les plus courants sont dans la figure 5 :

- **Sub-pixel** : Dans l'étude de Shi et al. [20], une convolution produit s^2 fois plus de canaux, puis un réarrangement spatial génère l'image HR. Le schéma est efficace, mais peut induire des artefacts selon la distribution des canaux et la structure des textures.
- **Convolution transposée** : opération end-to-end compatible avec les architectures convolutionnelles, mais sujette à des artefacts de recouvrement [4].

- **Meta-upscaling / échelles arbitraires** : génération de filtres conditionnée par le facteur d'agrandissement pour gérer des échelles continues ou non vues en entraînement, au prix d'exigences plus fortes en robustesse [1].




FIGURE 5 – Méthodes d'upsampling : (a) Convolution transposée (b) Sub-pixel. [10]

3.4.2 Optimisation des paramètres

L'évaluation et l'optimisation des paramètres sont des étapes cruciales pour tous les modèles d'apprentissage profond, ce qui est présenté dans la section 2.2.

Les modèles SISR basés sur l'apprentissage profond peuvent être principalement divisés en méthodes d'apprentissage supervisé et méthodes d'apprentissage non supervisé. Nous désignons généralement la méthode d'entraînement utilisant des images LR-HR appariées comme le paradigme d'apprentissage supervisé. Les méthodes non supervisées n'utilisent plus d'images appariées à basse résolution (LR) et haute résolution (HR) pour l'entraînement. Elles utilisent plutôt des images LR-HR non appariées (basées sur des approches de réseaux antagonistes génératifs) ou des techniques d'apprentissage auto-supervisé. Par exemple, ZSSR [21] construit un « ensemble de données d'entraînement » en combinant des images de test avec leurs versions sous-échantillonnées et des techniques d'augmentation des données, puis optimise le modèle à l'aide de fonctions de perte. En outre, l'apprentissage faiblement supervisé relève également des stratégies d'apprentissage non supervisé.

La fonction de perte guide le processus d'optimisation itératif du modèle en calculant l'erreur. Il existe plusieurs types des fonctions de perte.

La perte pixel est l'une des fonctions de perte les plus simples et les plus utilisées en SISR. Elle vise à mesurer l'écart entre l'image super-résolue et l'image de référence au niveau pixel par pixel, afin de rapprocher au maximum ces deux images. Elle inclut principalement la perte ℓ_1 , la perte MSE et la perte de Charbonnier (une variante différentiable de la perte ℓ_1) :

$$\mathcal{L}_{\ell_1}(I_{SR}, I_y) = \frac{1}{hwc} \sum_{i,j,k} |I_{SR}^{i,j,k} - I_y^{i,j,k}|, \quad (6)$$

$$\mathcal{L}_{\text{MSE}}(I_{SR}, I_y) = \frac{1}{hwc} \sum_{i,j,k} (I_{SR}^{i,j,k} - I_y^{i,j,k})^2, \quad (7)$$

$$\mathcal{L}_{\text{Char}}(I_{SR}, I_y) = \frac{1}{hwc} \sum_{i,j,k} \sqrt{(I_{SR}^{i,j,k} - I_y^{i,j,k})^2 + \epsilon^2}, \quad (8)$$

où h , w et c désignent respectivement la hauteur, la largeur et le nombre de canaux de l'image. Le terme ϵ est une constante de stabilité numérique, généralement fixée à 10^{-3} . Comme la plupart des indicateurs d'évaluation courants sont fortement corrélés aux différences pixel à pixel, la perte pixel reste largement employée. Néanmoins, les images reconstruites à l'aide de ce type de perte manquent souvent de détails haute fréquence, ce qui peut conduire à une qualité visuelle inférieure.

La perte de contenu mesure l'écart sémantique entre l'image super-résolue I_{SR} et l'image de référence I_y en comparant leurs représentations de haut niveau extraites par un réseau de classification pré-entraîné ϕ . En notant $\phi_{(l)}(\cdot)$ la carte de caractéristiques à la couche l , de dimensions (h_l, w_l, c_l) , on peut définir :

$$\mathcal{L}_{\text{Cont}}(I_{SR}, I_y, \phi) = \frac{1}{h_l w_l c_l} \sum_{i,j,k} \left(\phi_{(l)}^{i,j,k}(I_{SR}) - \phi_{(l)}^{i,j,k}(I_y) \right)^2, \quad (9)$$

où $\phi_{(l)}^{i,j,k}(\cdot)$ désigne la valeur du tenseur de caractéristiques à la position spatiale (i, j) et au canal k . Ici, h_l , w_l et c_l représentent respectivement la hauteur, la largeur et le nombre de canaux de la carte de caractéristiques à la couche l . L'utilisation de cette perte vise à rendre les effets visuels des deux images aussi cohérents que possible, car la comparaison se fait dans un espace de représentation sémantique plutôt qu'au niveau pixel. Les réseaux ϕ les plus couramment utilisés pour extraire ces caractéristiques sont VGG [22] et ResNet[9] (pré-entraînés).

Afin de rendre l'image super-résolue plus réaliste, des réseaux antagonistes génératifs (GAN) peuvent être introduits dans la SISR. Un GAN est composé d'un générateur G et d'un discriminateur D : le générateur produit une image SR synthétique à partir de l'entrée LR I_x , tandis que le discriminateur cherche à distinguer les images générées des images réelles. Dans le modèle SRGAN [9], une forme classique de perte adversariale (basée sur l'entropie croisée) pour entraîner le générateur est :

$$\mathcal{L}_{\text{adv}}(I_x, G, D) = \sum_{n=1}^N -\log \left(D(G(I_x^{(n)})) \right), \quad (10)$$

où N est le nombre d'échantillons considérés, $G(I_x^{(n)})$ désigne l'image super-résolue reconstruite à partir de la n -ième image LR, et $D(\cdot)$ renvoie la probabilité attribuée par le discriminateur que l'échantillon soit réel. L'optimisation conjointe de G et D encourage G à produire des textures visuellement plausibles, au prix d'un compromis distorsion-perception et d'une optimisation généralement plus délicate.

3.5 Méthodes avancées récentes

Ces dernières années, grâce au développement rapide des technologies d'apprentissage profond, les méthodes de super-résolution d'images ont connu des progrès significatifs, tant au niveau de la structure des modèles que du paradigme de modélisation. En particulier, l'émergence des réseaux de type Transformer (Liang et al., 2021 [11]), des modèles génératifs tels que les GAN (Wang et al., 2021 [25]) et les modèles de diffusion (Rombach et al., 2022 [18]) et des méthodes de fusion multimodale a considérablement amélioré la

capacité des modèles à modéliser les dépendances globales et leur qualité perceptive.

Les modèles de super-résolution basés sur les transformeurs, grâce à l'introduction de mécanismes d'auto-attention, capturent mieux les corrélations entre les pixels éloignés dans une image, contribuant ainsi à la restitution d'informations structurelles globalement cohérentes. Par exemple, des modèles tels que SwinIR utilisent des mécanismes d'attention hiérarchiques, garantissant à la fois une précision de reconstruction élevée et une grande efficacité de calcul (Liang et al., 2021 [11]).

Parallèlement, les modèles génératifs suscitent un intérêt croissant dans le domaine de la super-résolution. Les SRGAN, représentés par les réseaux antagonistes génératifs (GAN), permettent de générer des détails et des textures plus réalistes et naturels, mais au détriment souvent de métriques traditionnelles telles que le PSNR, tout en améliorant la qualité perçue (Ledig et al., 2017 [8]). Des travaux antérieurs ont également mis en évidence un compromis entre la qualité perçue et l'erreur de reconstruction (Blau & Michaeli, 2018 [2]). De plus, les modèles de diffusion, en tant que nouveau paradigme génératif, ont démontré d'excellentes capacités de restitution des détails dans les tâches de super-résolution (Saharia et al., 2022 [13]).

S'appuyant sur ces travaux, des recherches récentes ont exploré l'intégration d'informations sémantiques de haut niveau dans le processus de reconstruction en super-résolution, donnant naissance aux méthodes multimodales. Parmi celles-ci, le modèle CoSeR propose le concept de «super-résolution cognitive», qui génère des représentations cognitives à partir d'images basse résolution en fusionnant les représentations d'images avec des capacités de compréhension du langage. Ces représentations guident la reconstruction d'images haute résolution, aboutissant à des résultats de reconstruction plus pertinents en termes de cohérence sémantique (Sun et al., 2023 [23]).

Globalement, ces méthodes avancées démontrent l'évolution de la technologie de super-résolution, passant de la simple restauration des détails locaux à la combinaison de la structure globale et des informations sémantiques, offrant de nouvelles idées pour parvenir à une reconstruction d'image de meilleure qualité et plus cohérente sur le plan perceptif.

3.6 Limites et perspectives

Malgré les progrès significatifs réalisés ces dernières années dans le domaine de la super-résolution d'images, les méthodes existantes présentent encore certaines limitations. Premièrement, de nombreux modèles d'apprentissage profond reposent sur des hypothèses de dégradation idéalisées lors de leur entraînement et sont principalement entraînés sur des données synthétiques, ce qui limite leur capacité de généralisation aux scènes réelles.

Deuxièmement, un compromis existe entre les métriques numériques et la qualité perçue dans la reconstruction en super-résolution. Les méthodes d'optimisation des métriques, telles que le PSNR et le SSIM, tendent à produire des résultats plus lisses, tandis que les modèles génératifs, qui privilégient la qualité perçue tout en générant des détails de texture plus réalistes, peuvent introduire des artefacts.

De plus, les modèles avancés proposés ces dernières années, tels que ceux basés sur les Transformers, les modèles de diffusion et la fusion multimodale, présentent généralement une complexité de calcul et une surcharge de stockage élevées, ce qui limite leur application aux systèmes en temps réel.

Plusieurs pistes méritent une attention particulière dans les recherches futures. D'une part, il convient d'explorer davantage le développement de modèles de super-résolution plus robustes face à la dégradation réelle, leur permettant de s'adapter à diverses scènes complexes sans hypothèses de dégradation trop restrictives. Par ailleurs, l'intégration d'informations sémantiques de plus haut niveau dans le processus de super-résolution devrait améliorer la cohérence sémantique des résultats de reconstruction tout en préservant le réalisme des détails. De plus, la conception de structures de réseau plus légères et efficaces, combinée à des techniques de compression et d'accélération de modèles, constitue également une voie importante pour favoriser l'application pratique des méthodes de super-résolution.

4 Comparaison des modèles de super-résolution

Dans ce chapitre, nous avons sélectionné plusieurs méthodes de super-résolution d'images représentatives à des fins de comparaison expérimentale. Bien que ces méthodes diffèrent par la complexité de leur modèle et leur difficulté d'implémentation, elles se concentrent toutes sur la super-résolution d'images uniques et sont applicables à la mise à l'échelle et à l'amélioration de la résolution d'images dans des scénarios d'ingénierie pratique.

4.1 Modèles principaux étudiés

4.1.1 ESPCN

ESPCN (Efficient Sub-Pixel Convolutional Neural Network) est un modèle de super-résolution d'images profond, proposé par Shi et al. [20], qui repose sur des réseaux de neurones convolutifs (CNN). Contrairement aux méthodes traditionnelles de super-résolution basées sur CNN, qui interpolent d'abord l'image basse résolution (LR) vers l'espace haute résolution (HR) avant d'extraire des caractéristiques, l'ESPCN déplace l'opération de suréchantillonnage à la toute fin du réseau. Ce choix architectural permet d'effectuer l'ensemble des opérations de convolution et d'extraction de caractéristiques dans l'espace basse résolution, réduisant ainsi considérablement la complexité calculatoire et la consommation de mémoire.

Le mécanisme clé de l'ESPCN présenté dans la figure 6 est la couche de convolution sous-pixel (également appelée Periodic Shuffling), qui réalise la montée en résolution en réarrangeant les canaux des cartes de caractéristiques en dimensions spatiales. Plus précisément, la dernière couche convolutionnelle produit des cartes de caractéristiques avec un nombre de canaux égal à $C \times r^2$ (où C est le nombre de canaux de l'image de sortie et r est le facteur de suréchantillonnage). L'opération de réarrangement périodique regroupe ensuite ces r^2 canaux en une seule carte de caractéristiques de résolution r fois supérieure,

généralisant directement l'image HR sans recourir à des opérations d'interpolation ou de déconvolution coûteuses.




FIGURE 6 – La structure du ESPCN [20]

Cela permet à l'ESPCN d'atteindre un compromis optimal entre qualité de reconstruction et efficacité calculatoire. Les expériences menées par les auteurs montrent que l'ESPCN surpasse les méthodes concurrentes (telles que CNN et TNRD) en termes de PSNR (Peak Signal-to-Noise Ratio) sur des jeux de données standards, tout en étant jusqu'à 10 fois plus rapide sur GPU, ce qui lui permet de traiter des vidéos HD en temps réel.

4.1.2 Real-ESRGAN

Real-ESRGAN est une méthode de super-résolution, introduite par Wang et al.[25], basée sur les réseaux antagonistes génératifs (GAN), conçue pour améliorer la qualité perceptive des images reconstruites. Contrairement aux méthodes de super-résolution classiques basées sur les réseaux de neurones convolutifs, Real-ESRGAN ne vise pas uniquement la précision de reconstruction au niveau du pixel, mais se concentre plutôt sur le naturel visuel et la richesse des détails de l'image.

Cette méthode introduit un mécanisme d'apprentissage antagoniste entre le générateur et le discriminateur, permettant au modèle d'apprendre les détails haute fréquence qui correspondent mieux à la perception visuelle humaine. Pendant l'apprentissage, le générateur tente de produire les images haute résolution les plus réalistes possibles, tandis que le discriminateur distingue les images réelles des résultats générés, améliorant ainsi continuellement la qualité de la génération. Ce mécanisme confère à Real-ESRGAN un avantage significatif en matière de restauration de textures et d'amélioration des détails.

Dans cette expérience, Real-ESRGAN a été utilisé directement comme modèle pré-entraîné pour l'inférence, sans apprentissage supplémentaire ni réglage de paramètres pour des images de test spécifiques.

4.1.3 SwinIR

SwinIR est un modèle de restauration d'images, introduit par Liang et al. [11], basé sur l'architecture Transformer. Son principe consiste à modéliser les dépendances à longue portée dans les images grâce à un mécanisme d'auto-attention. Contrairement aux méthodes de super-résolution classiques basées sur les réseaux de neurones convolutifs, SwinIR ne se limite plus à un champ réceptif local, mais capture les informations structurelles de

l'image sur une zone plus étendue, améliorant ainsi les résultats de reconstruction.

S'appuyant sur la structure Swin Transformer, ce modèle réduit considérablement la complexité de calcul tout en conservant ses capacités de modélisation grâce à un mécanisme d'auto-attention par fenêtre. Cette conception permet à SwinIR de maintenir une grande efficacité tout en préservant les détails locaux et la cohérence globale, ce qui le rend particulièrement adapté au traitement des régions d'images présentant des structures complexes ou des textures riches.

Dans cette expérience, SwinIR a également été testé pour l'inférence en tant que modèle pré-entraîné, sans entraînement supplémentaire sur des images de test spécifiques.

4.1.4 Difussion upscale

Stable Diffusion $\times 4$ Upscaler est un modèle de diffusion officiellement publié par Stability AI, spécialement conçu pour l'upscaling d'images 4x. Il appartient à la famille Stable Diffusion, mais contrairement aux modèles standard de conversion texte-image (tels que SD 1.5 ou SDXL), sa tâche principale est la super-résolution. Cela implique d'agrandir les images à basse résolution d'un facteur quatre tout en s'efforçant de préserver ou d'améliorer les détails, la texture et la clarté.

Le modèle suit le paradigme des modèles de diffusion : au lieu d'apprendre une simple interpolation déterministe, il reconstruit une image haute résolution via un processus itératif de débruitage. On part d'un état fortement bruité, puis un réseau de débruitage est appliqué itérativement pour remonter vers une image propre. Cette famille de modèles se distingue par une excellente qualité de synthèse et un contrôle possible via des mécanismes de guidage/conditionnement. Néanmoins, une diffusion opérant directement en espace pixel est coûteuse, car elle requiert de nombreuses évaluations successives du réseau dans un espace de très grande dimension.




FIGURE 7 – La structure du LDM [19]

Pour réduire ce coût tout en conservant la qualité, Rombach et al. [19] proposent les Latent Diffusion Models (LDM) : l'idée est de séparer (i) une compression perceptuelle réalisée par un autoencodeur (encodeur E, décodeur D) et (ii) l'apprentissage/échantillonnage

diffusion dans un espace latent plus compact, où les détails imperceptibles sont déjà filtrés. Le débruitage est typiquement assuré par un U-Net conditionné par le temps, ce qui exploite bien les biais inductifs spatiaux tout en diminuant fortement le coût de calcul.

L'inférence prend en entrée : une image (basse résolution ou redimensionnée) et un prompt textuel qui oriente la nature des détails reconstruits, et produit une image upscalée d'un facteur $\times 4$. Avant l'inférence, l'image d'entrée est éventuellement réduite pour que son plus grand côté ne dépasse pas `max_side` (par défaut 128) afin d'assurer une exécution robuste sur CPU. La super-résolution est ensuite appliquée avec un nombre d'itérations `steps` (par défaut 25), et les résultats sont sauvegardés automatiquement dans un dossier de sortie avec un suffixe `_x4`.

Dans ce travail, le modèle de diffusion n'a pas fait l'objet d'expérimentations approfondies ; il a simplement été appelé et testé à l'aide de bibliothèques Python existantes. Étant donné que de tels modèles présentent généralement une complexité de calcul élevée et des exigences importantes en matière de mémoire GPU et de temps d'inférence, leur entraînement et leur évaluation systématiques s'avèrent difficiles dans les conditions expérimentales actuelles.



FIGURE 8 – Résultats de super-résolution obtenus avec le modèle de diffusion

On observe des images générées par ce modèle dans la figure 8. Ce modèle améliore la qualité perceptive en reconstruisant des textures plausibles, et leurs détails sont généralement très marqués. Sur les zones à forte densité de textures (comme les crins de l'animal sur la première image ou la végétation sur la deuxième), les détails restaurés sont visuellement convaincants. Cependant, elles comportent un risque d'introduire des artefacts ou des détails décalés par rapport à la vérité terrain : par exemple, sur la deuxième image du jeu de données, la texture de la peau est transformée en texture de bois ; sur la quatrième image (jeune fille), la jonction entre le coin inférieur droit du visage et le cou présente un motif fictif et incohérent.

4.1.5 Réseau CoSeR

CoSeR est un modèle de super-résolution cognitif proposé par Sun et al. en 2024 [23], qui se distingue des approches traditionnelles en introduisant une compréhension sémantique de haut niveau dans le processus de reconstruction. Contrairement aux méthodes classiques centrées sur la restauration pixelique locale, CoSeR associe les caractéristiques visuelles des images à des informations langagières pré-entraînées, afin de simuler un raisonnement cognitif humain : comprendre d'abord le contenu sémantique, puis reconstruire

les détails.

Le principal apport de ce modèle réside dans trois innovations clés. Premièrement, un encodeur cognitif basé sur CLIP et Q-Former extrait des embeddings riches qui fusionnent la sémantique globale et l'apparence locale de l'image basse résolution. Deuxièmement, le modèle génère automatiquement des images de référence sémantiquement alignées à l'aide d'un modèle de diffusion, fournissant des informations explicites pour la génération de textures réalistes. Troisièmement, un module d'attention unifié AiA intègre simultanément les caractéristiques de l'image d'entrée, les embeddings cognitifs et les références générées, ce qui améliore à la fois la fidélité structurale et la cohérence sémantique.

Par rapport aux méthodes existantes, CoSeR résout efficacement les distorsions sémantiques et les incohérences de contenu souvent observées dans les résultats de super-résolution classiques. Il atteint des performances à l'état de l'art sur des données réelles, en particulier pour les scénarios complexes où la compréhension du contenu est essentielle.




FIGURE 9 – La structure de CoSeR [23].

4.2 Protocole expérimental

4.2.1 Jeu de données et configuration générale

Afin d'assurer une comparaison aussi équitable que possible entre les différents modèles de super-résolution, toutes les expériences de ce chapitre sont réalisées à partir du jeu de données standard **Set14**. Une partie de celle-ci est représentée sur la figure 10. Ce jeu de données est couramment utilisé comme référence dans l'évaluation de méthodes de super-résolution mono-image.

Dans notre cadre expérimental, les images haute résolution de référence proviennent du dossier **GTmod12**, tandis que les entrées basse résolution sont issues des dossiers **LRbicx2**, **LRbicx3** et **LRbicx4**, correspondant respectivement aux facteurs d'agrandissement $\times 2$, $\times 3$ et $\times 4$. Cette organisation permet de conserver un protocole homogène pour l'ensemble des essais et de comparer les modèles sur exactement les mêmes données d'entrée.

Le cadre expérimental retenu porte principalement sur quatre modèles représentatifs de familles architecturales différentes :




FIGURE 10 – Images basse résolution (LR) issues du jeu de données Set14

- **ESPCN**, pour les approches convolutionnelles légères ;
- **Real-ESRGAN**, pour les méthodes adversariales orientées qualité perceptive ;
- **SwinIR**, pour les architectures de type Transformer ;
- **CoSeR**, pour les approches génératives cognitives basées sur la diffusion.

Ces quatre modèles sont comparés de manière systématique sur **trois facteurs d'échelle** ($\times 2$, $\times 3$, $\times 4$), ce qui conduit à un total de douze configurations expérimentales.

4.2.2 Conditions d'inférence et principe de comparaison

Pour garantir la comparabilité des résultats, toutes les méthodes sont appliquées selon un flux de traitement unifié. Les modèles sont utilisés en mode inférence à partir de poids pré-entraînés, sans phase supplémentaire de réapprentissage ni d'ajustement fin sur les images de test. Ce choix méthodologique vise à évaluer les performances pratiques des modèles dans un cadre reproductible, proche d'un usage réel, où l'on souhaite comparer directement plusieurs solutions existantes sur une même base d'images.

Sur le plan logiciel, l'environnement expérimental repose sur une implémentation en **Python + PyTorch**, avec un script d'évaluation commun, `evaluate_sr.py`, chargé de calculer les métriques numériques sur l'ensemble des sorties produites. Les résultats de chaque modèle et de chaque facteur d'échelle sont regroupés dans une arborescence commune, ce qui permet de centraliser à la fois les images générées et les mesures quantitatives correspondantes. Cette homogénéité d'exécution et d'évaluation constitue un élément important du protocole, car elle réduit le risque d'introduire des biais liés à des traitements différents selon les modèles.

En plus des quatre modèles étudiés, nous utilisons interpolation bicubique comme méthode de référence. Cette baseline présente l'avantage d'être simple, stable et peu coûteuse en calcul. Elle ne repose sur aucun apprentissage profond, mais elle fournit un point de comparaison utile pour mesurer le gain réel apporté par les modèles de super-résolution modernes. Dans le cadre de ce chapitre, elle joue donc le rôle de référence minimale, à la fois pour l'analyse visuelle et pour l'interprétation des résultats quantitatifs.

4.2.3 Détails techniques des modèles comparés

Afin de mieux situer les modèles retenus dans notre étude, le tableau 1 résume les quatre approches comparées selon leur type d'architecture, leur principe technique principal et leur caractéristique représentative. Cette synthèse permet de montrer que notre

comparaison couvre des familles de modèles très différentes, depuis les réseaux convolutifs légers jusqu'aux modèles génératifs fondés sur la diffusion.

TABLE 1 – Résumé des quatre modèles de super-résolution comparés

Modèle	Type d'architecture	Technique principale	Caractéristique
ESPCN	CNN léger	PixelShuffle, 3 couches convolutives	Très rapide, peu de paramètres
Real-ESRGAN	GAN	Blocs RRDB + discriminateur	Bonne qualité perceptive
SwinIR	Transformer	Auto-attention par fenêtres glissantes	Très bon compromis global
CoSeR	Modèle de diffusion	Diffusion latente + Q-Former	Modèle le plus complexe

Parmi les modèles étudiés, ESPCN représente l'approche la plus légère. Son pipeline repose sur trois couches de convolution pour extraire les caractéristiques dans l'espace basse résolution, puis sur une opération de *PixelShuffle* pour effectuer l'upsampling à la fin du réseau. Dans notre implémentation, le traitement de l'image est réalisé dans l'espace *YCbCr* : seule la composante de luminance *Y* est super-résolue par le modèle, tandis que les composantes chromatiques *Cb* et *Cr* sont redimensionnées par interpolation bicubique avant la fusion finale. Cette conception réduit fortement le coût de calcul et explique la rapidité d'inférence de ce modèle, ce qui en fait une solution particulièrement adaptée aux scénarios à ressources limitées.

Real-ESRGAN correspond à une approche générative fondée sur les réseaux antagonistes. Le générateur s'appuie sur des blocs *RRDB* (*Residual-in-Residual Dense Blocks*), tandis que l'apprentissage repose sur un discriminateur chargé de distinguer les images reconstruites des images réelles. Un élément important de cette méthode est l'utilisation d'un modèle de dégradation en deux étapes, combinant flou, bruit et compression JPEG, afin de mieux simuler les dégradations du monde réel. Dans notre travail, l'inférence est réalisée à partir de poids pré-entraînés, ce qui permet d'évaluer directement sa capacité à restaurer des textures visuellement riches et plausibles sur des images dégradées.

SwinIR représente la famille des modèles basés sur les Transformers. Son architecture repose sur des blocs *Swin Transformer*, qui utilisent un mécanisme d'auto-attention locale par fenêtres 8×8 , associé à un décalage des fenêtres entre blocs successifs. Cette stratégie permet de capturer à la fois des dépendances locales et des relations plus globales dans l'image, tout en maîtrisant la complexité du calcul. L'étape de reconstruction finale combine convolution et *PixelShuffle*. Le modèle a été pré-entraîné sur le jeu de données DF2K et nous utilisons dans nos expériences les poids correspondants aux facteurs $\times 2$, $\times 3$ et $\times 4$. Dans l'ensemble, SwinIR constitue le modèle le plus équilibré de notre comparaison, notamment du point de vue des métriques objectives.

Enfin, CoSeR est le modèle le plus complexe du benchmark. Il s'agit d'une approche de super-résolution cognitive fondée sur *Stable Diffusion v2.1*, enrichie par un encodeur *Q-Former* utilisant cinquante *query tokens* pour extraire des informations sémantiques de

haut niveau. Son pipeline d'inférence comprend plusieurs étapes successives : l'image LR est d'abord complétée jusqu'à une taille multiple de 64, puis redimensionnée en 512×512 ; elle est ensuite encodée par un module *VQGAN*, transformée dans un espace latent, enrichie par les représentations cognitives du *Q-Former*, puis traitée par un *U-Net* de diffusion avec attention croisée. Après l'échantillonnage *DDIM*, l'image est décodée et recadrée afin de supprimer les bordures ajoutées. Cette architecture vise moins une simple fidélité pixelique qu'une reconstruction plus riche sémantiquement, ce qui explique son intérêt particulier dans les approches génératives avancées.

Ainsi, les quatre modèles comparés couvrent un spectre méthodologique large : ESPCN met l'accent sur l'efficacité, Real-ESRGAN sur la qualité perceptive, SwinIR sur l'équilibre entre fidélité et robustesse, et CoSeR sur l'intégration d'une compréhension sémantique dans la reconstruction haute résolution. Cette diversité justifie leur sélection dans notre protocole de comparaison.

4.3 Comparaison quantitative des résultats

Afin d'évaluer objectivement les performances des différentes méthodes de super-résolution, nous utilisons trois indicateurs classiques : le PSNR, le SSIM et le LPIPS. Ces métriques mesurent des aspects complémentaires de la qualité de reconstruction, ce qui permet d'obtenir une évaluation plus complète des résultats expérimentaux.

4.3.1 Méthodes d'évaluation utilisées

Le PSNR (*Peak Signal-to-Noise Ratio*) [16] est une mesure fondée sur l'erreur pixel à pixel entre l'image reconstruite et l'image de référence haute résolution. Il est calculé à partir de l'erreur quadratique moyenne (MSE) :

$$\text{MSE} = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (I(i, j) - K(i, j))^2 \quad (11)$$

où I désigne l'image de référence, K l'image reconstruite, et H, W les dimensions de l'image. Le PSNR s'écrit ensuite :

$$\text{PSNR} = 10 \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (12)$$

où MAX_I représente la valeur maximale possible d'un pixel. Une valeur plus élevée de PSNR indique une erreur de reconstruction plus faible et donc une meilleure fidélité numérique. Cependant, cet indicateur reste limité, car il ne reflète pas toujours correctement la qualité visuelle perçue par l'œil humain.

Le SSIM (*Structural Similarity Index*) [3] a été introduit pour mieux prendre en compte la perception visuelle. Contrairement au PSNR, il ne compare pas seulement les différences de pixels, mais évalue aussi la similarité de structure entre deux signaux non négatifs x et y à partir de la luminance $l(x, y)$, du contraste $c(x, y)$ et de la structure locale $s(x, y)$:

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1}, \quad (13)$$

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2}, \quad (14)$$

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3}. \quad (15)$$

où $C_1 = (K_1L)^2$, $C_2 = (K_2L)^2$ et $C_3 = C_2/2$ sont de petites constantes ; L est la plage dynamique des valeurs de pixels, et $K_1 \ll 1$ et $K_2 \ll 1$ sont des constantes scalaires. Les constantes C_1 , C_2 et C_3 assurent la stabilité lorsque le dénominateur tend vers zéro. Sa formule classique est :

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}$$

où μ_x, μ_y sont les moyennes des deux images, σ_x^2, σ_y^2 leurs variances, et σ_{xy} leur covariance. Le SSIM est généralement compris entre 0 et 1, et une valeur plus proche de 1 signifie que l'image reconstruite préserve mieux les structures de l'image de référence.

Le LPIPS (*Learned Perceptual Image Patch Similarity*) [29] est une métrique perceptuelle plus récente, conçue pour mieux correspondre au jugement visuel humain. Au lieu de comparer directement les pixels, elle compare les représentations de haut niveau extraites par un réseau de neurones pré-entraîné. De manière générale, elle peut s'écrire sous la forme d'une distance entre caractéristiques profondes :

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \left\| w_l \odot (\hat{f}_l(x)_{hw} - \hat{f}_l(y)_{hw}) \right\|_2^2 \quad (16)$$

où $f_l(\cdot)$ représente les caractéristiques extraites à la couche l , $\hat{f}_l$ les caractéristiques normalisées, et w_l les poids associés à chaque couche. Contrairement au PSNR et au SSIM, pour le LPIPS, une valeur plus faible indique une meilleure qualité perceptuelle, c'est-à-dire que l'image reconstruite est visuellement plus proche de l'image réelle.

Ces trois indicateurs sont complémentaires. Le PSNR mesure principalement la fidélité numérique, le SSIM évalue la préservation des structures, tandis que le LPIPS se concentre sur la similarité perceptuelle. Dans le cadre de la super-résolution, il est donc nécessaire de les considérer conjointement : un modèle peut obtenir un PSNR élevé tout en produisant une image visuellement trop lisse, alors qu'un autre modèle peut présenter un LPIPS plus faible grâce à une restitution plus naturelle des textures.

Après avoir appliqué les différentes méthodes dans la transformation de super-résolution des mêmes 14 figures, on fait des calculs entre les images générées et les images de haute résolution pour obtenir les valeurs moyennes.

4.3.2 Analyse des différents modèles

Les résultats quantitatifs obtenus sur le jeu de données Set14 sont présentés dans le tableau 2. Contrairement à une moyenne globale unique, cette présentation par facteur

d'échelle permet de mieux observer l'évolution des performances lorsque la difficulté de la tâche augmente.

TABLE 2 – Résultats quantitatifs sur Set14 pour les différents modèles de super-résolution

Modèle	Facteur d'échelle	PSNR (dB)	SSIM	LPIPS
SwinIR	$\times 2$	34.41	0.9250	0.083
	$\times 3$	30.92	0.8540	0.190
	$\times 4$	29.08	0.7950	0.268
ESPCN	$\times 2$	32.32	0.9060	0.107
	$\times 3$	29.20	0.8200	0.236
	$\times 4$	27.40	0.7500	0.331
Real-ESRGAN	$\times 2$	28.16	0.8110	0.154
	$\times 3$	26.63	0.7620	0.189
	$\times 4$	25.40	0.6960	0.236
CoSeR	$\times 2$	24.51	0.7440	0.130
	$\times 3$	24.26	0.6890	0.180
	$\times 4$	24.02	0.6500	0.227

De manière générale, on observe que les valeurs de PSNR et de SSIM diminuent lorsque le facteur d'échelle augmente, ce qui est cohérent avec la difficulté croissante de la super-résolution. Cette tendance apparaît pour l'ensemble des modèles, mais avec des amplitudes différentes selon leur architecture.

SwinIR obtient systématiquement les meilleurs résultats en PSNR et en SSIM pour les trois facteurs d'échelle. Il constitue donc le modèle le plus équilibré de notre comparaison, avec une excellente fidélité numérique et une très bonne préservation de la structure globale de l'image.

ESPCN se place globalement en deuxième position. Ses performances restent relativement proches de celles de SwinIR, en particulier à $\times 2$ et $\times 3$, ce qui montre qu'un modèle léger peut tout de même fournir une reconstruction de bonne qualité. Compte tenu de sa rapidité et de sa simplicité, ESPCN représente un très bon compromis entre efficacité et performance.

Real-ESRGAN présente des résultats plus faibles en PSNR et en SSIM, mais conserve des valeurs de LPIPS compétitives, notamment à $\times 3$ et $\times 4$. Cela confirme qu'il privilégie davantage la qualité perceptive et la restitution de textures visuellement riches qu'une stricte fidélité pixel à pixel.

Enfin, CoSeR obtient les valeurs les plus faibles en PSNR et en SSIM, mais ses scores de LPIPS restent relativement bons, surtout à $\times 2$ et $\times 3$. Ce comportement suggère que, malgré une fidélité numérique plus limitée, ce modèle possède un intérêt réel pour la génération de détails perceptuellement plausibles et pour une reconstruction plus riche sur le plan sémantique.

Dans l'ensemble, les résultats quantitatifs montrent donc que SwinIR est le meilleur choix global, que ESPCN offre le meilleur rapport entre coût de calcul et qualité de reconstruction, tandis que Real-ESRGAN et CoSeR se distinguent davantage par leur orientation perceptive.

4.4 Comparaison qualitative des résultats

La figure 12 présente une comparaison visuelle entre l'interpolation bicubique et les quatre modèles de super-résolution évalués (ESPCN, Real-ESRGAN, SwinIR, CoSeR) sur plusieurs images représentatives du jeu de données Set14. Nous pouvons comparer les résultats des différents modèles avec des images de haute résolution représentées dans la figure 11. Cette analyse qualitative complète directement la section précédente : elle permet de vérifier visuellement si les tendances observées sur les métriques PSNR, SSIM et LPIPS se traduisent bien dans les images reconstruites.




FIGURE 11 – Images HR (haute résolution) dans la base de données

De manière générale, les observations visuelles confirment les résultats quantitatifs.

Le modèle SwinIR, qui obtenait les meilleures valeurs en PSNR et en SSIM dans la section 4.3, fournit également le rendu le plus équilibré sur le plan visuel : les contours sont nets, les structures globales restent cohérentes, et les artefacts sont peu nombreux. Sur l'image du pont, par exemple, les lignes horizontales et les transitions entre les zones claires et sombres sont mieux préservées. De même, sur le visage de la jeune fille, la reconstruction reste stable et naturelle, sans déformation évidente. Cette cohérence visuelle confirme que les bonnes performances numériques de SwinIR correspondent à une véritable qualité de reconstruction, et pas seulement à une optimisation artificielle des métriques.

ESPCN, qui se classait globalement en deuxième position dans l'analyse quantitative, présente lui aussi une amélioration nette par rapport à l'interpolation bicubique. Les contours sont plus précis, les formes principales sont mieux restituées, et l'image gagne en netteté globale. Toutefois, cette amélioration reste plus modérée que celle obtenue avec SwinIR. Les textures fines demeurent plus limitées, en particulier dans les zones riches en micro-détails, comme les poils de l'animal ou les ornements de l'image de la jeune fille. Cette observation est cohérente avec les scores quantitatifs : ESPCN conserve une bonne fidélité structurelle, mais sa capacité de restitution des détails fins reste inférieure à celle




FIGURE 12 – Comparaison qualitative des résultats de super-résolution sur les images du jeu de données Set14.

des modèles plus avancés.

Real-ESRGAN présente un comportement visuel différent, en accord avec son profil quantitatif. Dans la section 4.3, ce modèle obtenait des scores de PSNR et de SSIM plus faibles que SwinIR et ESPCN, mais des valeurs de LPIPS plus compétitives, ce qui suggérait une meilleure qualité perceptive. Cette tendance est bien visible dans la figure : Real-ESRGAN produit des textures plus riches, plus marquées, et parfois plus spectaculaires visuellement. Sur les zones denses en détails, comme les poils du babouin ou certains motifs du vêtement, l'image paraît plus expressive que celle produite par ESPCN. Cependant, cette richesse perceptive s'accompagne d'un risque plus élevé d'artefacts : certaines textures semblent artificielles ou légèrement décalées par rapport à l'image de référence. Par exemple, sur la deuxième image du jeu de données, la texture de la peau est transformée en texture de bois ; sur la quatrième image (jeune fille), la jonction entre le coin inférieur droit du visage et le cou présente un motif fictif et incohérent. Ainsi, les observations visuelles confirment bien le compromis mis en évidence par les métriques : Real-ESRGAN privilégie la perception au détriment d'une fidélité numérique stricte.

Le cas de CoSeR est également intéressant. D'après l'analyse quantitative, ce modèle obtenait les scores de PSNR et de SSIM les plus faibles, mais des valeurs de LPIPS relativement bonnes, ce qui laissait supposer une reconstruction perceptuellement plausible malgré une moindre fidélité pixelique. L'analyse visuelle confirme cette interprétation. CoSeR produit des images nettes et souvent cohérentes sur le plan sémantique, avec une bonne impression visuelle d'ensemble. Sur plusieurs exemples, le résultat paraît naturel et évite certains artefacts incohérents que l'on peut observer dans d'autres approches génératives. En revanche, lorsque l'on examine des détails très fins, notamment les bijoux ou certaines textures complexes, on constate que la reconstruction reste imparfaite et peut s'éloigner de la vérité terrain. Cela explique pourquoi le modèle reste moins performant sur les métriques objectives tout en conservant un intérêt perceptif réel.

Enfin, l'interpolation bicubique, utilisée comme référence, permet de mieux situer les gains apportés par les modèles étudiés. Son rendu reste globalement stable et sans artefact majeur, mais l'image apparaît nettement plus floue. Les contours sont adoucis et les détails haute fréquence sont largement perdus. Cette baseline montre donc clairement que les modèles de super-résolution modernes ne se contentent pas d'agrandir l'image, mais apportent une véritable reconstruction des structures et des textures.

Dans l'ensemble, la comparaison qualitative confirme donc les conclusions de la section 4.3. SwinIR apparaît comme le meilleur choix global grâce à son excellent équilibre entre fidélité, stabilité et qualité visuelle. ESPCN constitue une solution efficace et légère, capable d'améliorer nettement l'image sans coût important. De leur côté, Real-ESRGAN et CoSeR se distinguent par une orientation plus perceptive : ils peuvent produire des résultats visuellement plus riches, mais au prix d'un écart plus important par rapport à la référence haute résolution.

Pour synthétiser les caractéristiques clés et les compromis des quatre modèles de super-résolution évalués, la Table 3 présente une comparaison concise de leurs avantages et limites. Elle met en évidence les différences essentielles entre les modèles en termes de

vitesse, de restitution des détails, de cohérence sémantique et de contrôle des artefacts, offrant une référence pratique pour le choix du modèle adapté à différents scénarios d'application.

TABLE 3 – Comparaison des avantages et limites des quatre modèles de super-résolution

Modèle	Avantages	Inconvénients
ESPCN	Inférence très rapide et architecture légère Bonne restitution globale des structures Bon compromis efficacité / qualité	Restauration limitée des micro-textures Moins précis que SwinIR sur les détails fins Pas de compréhension sémantique
Real-ESRGAN	Textures riches et détails visuellement marqués Bonne qualité perceptive sur les zones denses Résultats souvent plus expressifs visuellement	Fidélité numérique plus faible Risque d'artefacts et de textures artificielles Possibles incohérences locales par rapport à la référence
SwinIR	Meilleur équilibre global entre fidélité et perception Contours nets et structures très stables Peu d'artefacts, excellente cohérence visuelle	Textures parfois moins riches que les modèles génératifs Rendu plus prudent sur certaines micro-textures Coût plus élevé qu'ESPCN
CoSeR	Rendu visuellement naturel Bonne cohérence sémantique globale Peu d'artefacts incohérents dans l'ensemble	Faible fidélité numérique (PSNR/SSIM) Prétraitement et pipeline plus complexes Détails fins parfois éloignés de la référence HR

4.5 Synthèse et applications pour la super-résolution

L'ensemble des expériences menées dans ce chapitre permet de dégager des recommandations concrètes pour l'intégration de la super-résolution dans une chaîne de génération de contenu procédural (PCG). Selon le type de contenu et les contraintes applicatives, le choix du modèle optimal varie considérablement.

Pour les applications nécessitant des performances temps réel, telles que le rendu dynamique dans les jeux vidéo ou la simulation interactive, ESPCN constitue le meilleur compromis. Sa légèreté architecturale (trois couches convolutives et une opération de PixelShuffle) lui permet d'atteindre des performances de traitement élevées avec un coût de calcul minimal. Avec un PSNR moyen de 27,42 dB et un SSIM de 0,75 sur le jeu de données Set14, ESPCN offre une qualité de reconstruction suffisante pour des textures procédurales simples telles que des mosaïques géométriques, des motifs répétitifs ou des cartes de hauteurs.

Pour les applications à haute fidélité structurelle, où la précision des contours et la cohérence géométrique sont primordiales — comme dans la super-résolution de cartes topographiques, de plans architecturaux procéduraux ou de scènes de simulation — SwinIR représente le choix le plus adapté. Il obtient les meilleures performances quantitatives globales (PSNR = 28,93 dB, SSIM = 0,79, LPIPS = 0,27), ce qui témoigne d'une excellente fidélité de reconstruction tout en limitant les artefacts visuels.

Pour les applications orientées qualité perceptive, telles que la génération de textures d'environnement pour des rendus artistiques, des cinématiques ou de la réalité virtuelle, Real-ESRGAN et CoSeR se distinguent. Real-ESRGAN produit des images visuellement riches, avec des détails texturaux fins et une apparence naturelle, au prix d'un PSNR plus faible (25,40 dB) mais d'un LPIPS compétitif (0,24). CoSeR, grâce à son encodeur cognitif basé sur CLIP et Q-Former, excelle dans les scènes complexes nécessitant une compréhension sémantique : ses reconstructions sont cohérentes sur le plan sémantique et présentent peu d'artefacts illogiques, même si ses métriques pixeliques (PSNR =

24,02 dB) restent inférieures aux modèles convolutifs.

Le modèle de diffusion (Stable Diffusion $\times 4$ Upscaler) présente un profil atypique : ses valeurs de PSNR et SSIM sont les plus faibles de la comparaison (17,04 dB et 0,34 respectivement), ce qui reflète sa nature générative plutôt que reconstructive. En revanche, il produit des images perceptivement riches et détaillées, particulièrement adaptées à des contenus artistiques ou stylisés. Dans le cadre PCG, son utilisation est recommandée pour la génération de textures de style ou d'arrière-plans complexes, où la cohérence sémantique prime sur la fidélité pixelique stricte.

Dans une perspective d'intégration dans une chaîne PCG complète, une stratégie hybride apparaît comme la plus pertinente. On pourrait envisager d'utiliser ESPCN pour le contenu bas niveau généré en grande quantité (géométries, heightmaps), SwinIR pour les assets nécessitant une précision structurelle (textures de surface, sprites), et Real-ESRGAN ou CoSeR pour les éléments visuellement saillants tels que les personnages ou les décors d'arrière-plan. Cette approche multicouche permettrait d'optimiser à la fois le coût de calcul global et la qualité visuelle perçue, en adaptant le modèle au contenu traité.

Enfin, ces résultats mettent en évidence que l'interpolation bicubique, bien que toujours utilisée comme baseline dans la littérature, ne constitue plus une solution acceptable pour des applications PCG modernes : même le modèle le plus léger (ESPCN) la surpasse sur toutes les métriques, tout en restant économe en ressources computationnelles.

5 Interface interactive et démonstration d'usage

Au-delà de la comparaison expérimentale entre plusieurs modèles de super-résolution, nous avons également développé une interface interactive intégrée dans le notebook principal du projet. Cette interface a pour objectif de transformer le cadre d'évaluation en un outil de démonstration et d'aide à la décision, permettant à l'utilisateur de choisir un modèle adapté à ses besoins, puis de lancer directement une inférence sur une image personnelle. Dans le projet SR_F, cette partie correspond aux deux dernières cellules du notebook principal sr.ipynb, qui relie les résultats expérimentaux à un usage plus concret et plus intuitif.


5.1 Assistant de recommandation de modèle

Le premier composant interactif, implémenté avec ipywidgets, agit comme un assistant de recommandation. L'utilisateur sélectionne trois critères à l'aide de boutons radio : le facteur d'agrandissement souhaité ($\times 2$, $\times 3$ ou $\times 4$), le temps d'attente acceptable, ainsi que la priorité d'optimisation entre fidélité, détails perceptifs et rapidité. Cette interface exploite directement les résultats quantitatifs obtenus sur Set14 afin de proposer automatiquement le modèle le plus pertinent dans chaque situation.

Le critère de temps repose sur une hiérarchie de vitesse définie dans le projet : ESPCN correspond au niveau 1, car il s'agit du modèle le plus rapide ; Real-ESRGAN correspond au niveau 2 ; SwinIR au niveau 3 ; enfin CoSeR correspond au niveau 4, puisqu'il s'appuie

sur un pipeline de diffusion beaucoup plus coûteux. À partir de cette hiérarchie, le système élimine automatiquement les modèles incompatibles avec la contrainte de temps choisie par l'utilisateur.

La logique de recommandation dépend ensuite de la priorité sélectionnée. Si l'utilisateur privilégie une sortie lisse ou fidèle à l'image originale, le système choisit le modèle ayant le meilleur PSNR. Si l'objectif principal est la richesse des détails et la qualité perceptive, la sélection repose sur le LPIPS, en privilégiant la valeur la plus faible. Enfin, si la priorité est la vitesse, le système combine d'abord la contrainte de rapidité, puis utilise le PSNR pour départager les candidats restants. Cette stratégie permet de relier directement l'analyse quantitative du chapitre précédent à une aide pratique au choix du modèle.



Modèle	PSNR (dB)	SSIM	LPIPS	Vitesse
RealESRGAN	25.4024	0.695977	0.236081	Moyen ◀ Recommandé
ESPCN	27.4041	0.749581	0.331003	Très rapide

FIGURE 13 – Interface de recommandation du modèle de super-résolution.

Comme le montre la figure 13, l'interface ne se limite pas à une présentation des modèles disponibles. Elle synthétise les contraintes d'usage et les résultats expérimentaux afin de proposer une recommandation directement exploitable. Cette étape constitue un lien concret entre l'évaluation quantitative et l'utilisation pratique des modèles.

5.2 Inférence sur image personnalisée

Le second composant interactif relie l'assistant de recommandation au moteur d'inférence réel. Une fois le modèle recommandé, l'utilisateur peut téléverser une image personnelle, puis exécuter la super-résolution à l'aide d'un bouton dédié. Le système prend en charge les formats d'image usuels, puis exécute automatiquement le pipeline correspondant au modèle sélectionné.

L'architecture de cette interface repose sur une chaîne de traitement unifiée. L'image chargée par l'utilisateur est d'abord enregistrée dans un répertoire temporaire. Le notebook lit ensuite en temps réel les paramètres déjà choisis dans le module de recommandation, puis appelle une fonction d'exécution spécifique selon le modèle retenu. Pour ESPCN, l'inférence est lancée à l'aide du script ESPCN/inference.py. Pour SwinIR, le système prépare automatiquement le nom du fichier en y ajoutant le suffixe correspondant au facteur d'échelle, puis appelle SwinIR/main_test_swinir.py. Pour Real-ESRGAN, l'exécution passe par Real-ESRGAN/inference_realesrgan.py. Enfin, pour CoSeR, le pipeline

inclut un prétraitement spécifique, une étape d'inférence via `scripts/inference.py`, puis un recadrage final afin d'éliminer les bordures ajoutées pendant la préparation de l'image.

L'interface affiche ensuite côte à côte l'image d'entrée et le résultat super-résolu, avec une hauteur d'affichage unifiée, ce qui facilite la comparaison visuelle immédiate. En complément, la résolution d'entrée et la résolution de sortie sont indiquées à l'utilisateur, ce qui permet de visualiser explicitement l'effet du facteur d'agrandissement. Une fois l'opération terminée, les fichiers temporaires sont supprimés afin de conserver un fonctionnement propre et reproductible.



FIGURE 14 – Interface de téléversement et d'inférence.

La figure 14 illustre cette seconde étape du workflow. Après la phase de recommandation, l'utilisateur peut directement tester le modèle sur une image personnelle, ce qui transforme le benchmark en un outil de démonstration complet.

5.3 Cas particulier du modèle CoSeR

Parmi les modèles intégrés dans l'interface, CoSeR nécessite une gestion particulière. Ce modèle génère systématiquement une sortie en $\times 4$, à partir d'une image prétraitée et redimensionnée dans un format compatible avec son pipeline interne. Ainsi, lorsque l'utilisateur choisit une sortie en $\times 2$ ou $\times 3$, le système procède d'abord au recadrage de l'image générée en $\times 4$, puis applique une interpolation bicubique pour obtenir la taille finale souhaitée. Cette étape permet d'intégrer CoSeR dans une interface commune malgré les contraintes propres à son architecture.

De plus, l'interface autorise pour ce modèle l'utilisation de prompts textuels positifs et négatifs. L'utilisateur peut donc orienter, au moins partiellement, la génération des détails perceptifs lorsque CoSeR est sélectionné. Cette possibilité distingue ce modèle des approches plus classiques et illustre l'intérêt des méthodes génératives conditionnées dans le cadre de la super-résolution.

5.4 Exemples de résultats générés

Afin d'illustrer concrètement l'usage de l'interface, nous présentons dans la figure 15 trois exemples de résultats obtenus avec Real-ESRGAN, SwinIR et CoSeR. Ces images permettent de visualiser les différences de rendu entre une approche perceptive fondée sur GAN, un modèle de type Transformer et un pipeline génératif cognitif basé sur la diffusion. Ces illustrations montrent que l'interface ne sert pas uniquement à recommander un modèle, mais permet également de comparer visuellement les rendus produits par différentes approches de super-résolution.




FIGURE 15 – Exemples de résultats générés par trois modèles de super-résolution intégrés dans l’interface interactive.

Ces exemples mettent en évidence des comportements cohérents avec l’analyse quantitative et qualitative présentée précédemment. Real-ESRGAN produit généralement des textures plus marquées et un rendu perceptif plus expressif. SwinIR fournit une reconstruction plus équilibrée, avec des structures nettes et une excellente stabilité globale. Enfin, CoSeR se distingue par un rendu souvent naturel et sémantiquement cohérent, bien que certains détails fins puissent rester éloignés de la référence.

5.5 Intérêt de l’interface dans le cadre du projet

Cette interface interactive constitue un prolongement naturel du protocole expérimental. Alors que les sections précédentes comparent les modèles à partir d’images de référence et de métriques objectives, l’interface permet de réutiliser directement ces résultats dans un scénario d’usage. Elle transforme ainsi le projet en un outil semi-opérationnel capable non seulement d’évaluer plusieurs méthodes, mais aussi de guider l’utilisateur vers un choix adapté à ses contraintes de temps, de qualité et de perception.

Sur le plan méthodologique, cette interface met également en valeur l’un des apports pratiques du projet : la construction d’un workflow complet, allant de la comparaison des modèles à la recommandation, puis à l’inférence sur image personnalisée. Elle relie ainsi la partie scientifique du rapport à une démonstration concrète de faisabilité et renforce l’intérêt applicatif du cadre SR_F.

6 Organisation des tâches

Le projet est organisé en sept phases successives, permettant d’aboutir aux deux livrables finaux attendus :

- 1er livrable : Rapport (incluant état de l’art, choix méthodologiques, protocole expérimental et analyse) ;
- 2e livrable : Codes (structure logicielle, implémentations, scripts de test/évaluation et reproductibilité).

Le projet suit une logique par phases successives, depuis la recherche bibliographique jusqu’à la rédaction finale et la soutenance, avec un pilotage transversal. Le planning OpenProject structure le travail en lots cohérents (Recherche → Sélection → Conception → Données → Implémentation → Évaluation → Final), en intégrant explicitement les périodes contraintes (Toussaint, Noël, examens S7, vacances d’hiver/printemps).

La phase recherche consolide la base scientifique du projet : rappel du contexte PCG et motivation (qualité visuelle limitée en basse/moyenne résolution), puis définition de la SR comme problème inverse (LR issue d'une dégradation, reconstruction HR) et revue structurée des approches classiques et deep learning (upsampling, fonctions de perte, compromis fidélité-perception), jusqu'aux méthodes récentes (Transformers, GAN, diffusion, multimodal).




FIGURE 16 – La phase recherche dans le diagramme de Gantt

Dans la phase sélection, on identifie des candidats représentatifs pour répondre à la problématique : disposer de modèles SR performants et compatibles avec l'usage PCG. La sélection s'appuie notamment sur une comparaison de modèles étudiés dans le rapport (ex. ESPCN, Real-ESRGAN, SwinIR) afin de cerner les compromis entre qualité perceptive, fidélité, robustesse aux dégradations et coût de calcul, puis de justifier un choix de modèle pour la suite.

La phase conception transforme le choix méthodologique en spécifications opérationnelles : définition du schéma LR→HR, choix des facteurs d'échelle, design du protocole expérimental et des critères d'évaluation, en cohérence avec la formulation "ill-posed" et le cadre d'optimisation présenté dans le rapport.

L'objectif de la phase données est de préparer des données adaptées à la SR : constitution de paires LR/HR, génération contrôlée des dégradations, découpage entraînement/validation/test et contrôles de qualité. Cette étape vise à éviter les biais (dégradations trop idéalisées) et à garantir que l'évaluation mesure bien la capacité du modèle

à améliorer le rendu visuel dans le contexte PCG.




FIGURE 17 – La phase données, conception et sélection dans le diagramme de Gantt

En terme de l'implémentation, on met en place l'environnement et la structure logicielle, puis on implémente le pipeline retenu, en particulier l'implémentation du modèle CoSeR décrite dans le plan du rapport, ainsi que les scripts nécessaires pour exécuter les modèles comparés, lancer des tests et produire des sorties SR. L'accent est mis sur une exécution stable et reproductible, conforme au livrable des codes.

L'évaluation regroupe l'évaluation qualitative (inspection visuelle, textures/contours, artefacts) et l'évaluation objective (métriques), puis l'analyse des résultats en lien avec les notions clés du rapport (compromis distorsion-perception, robustesse aux dégradations réelles vs synthétiques). Elle aboutit à un rapport d'évaluation permettant de conclure sur l'intérêt pratique de la SR pour rehausser la qualité des contenus PCG.

Enfin, on consolide les livrables : rédaction du rapport final (état de l'art, comparaison, choix, protocole, résultats et analyse) et finalisation du dépôt de code (nettoyage, documentation, scripts "run/eval", commandes utiles). Cette phase prépare également la soutenance en synthétisant clairement l'apport de la super-résolution dans la chaîne de génération procédurale.




FIGURE 18 – La phase d’implémentation, la phase d’évaluation et la phase finale dans le diagramme de Gantt

Conclusion

Ce projet a exploré l’intégration de la super-résolution (SR) dans une chaîne de génération de contenu procédural (PCG), en réponse à une problématique centrale : comment améliorer la qualité visuelle des contenus générés procéduralement sans augmenter de manière prohibitive les coûts de calcul et de stockage ?

Sur le plan de l’état de l’art, nous avons recensé et analysé les principales familles de méthodes SR, depuis l’interpolation bicubique jusqu’aux approches récentes basées sur les transformeurs (SwinIR) et les modèles génératifs (diffusion, CoSeR). Cette revue a permis de dégager les fondements théoriques nécessaires à la conception d’un protocole expérimental rigoureux.

Sur le plan expérimental, nous avons mis en place un cadre de comparaison équitable portant sur cinq modèles SR représentatifs — ESPCN, Real-ESRGAN, SwinIR, Stable Diffusion $\times 4$ Upscaler et CoSeR — ainsi qu’une interpolation bicubique comme référence. Les expériences ont été conduites sur le jeu de données standard Set14, avec des facteurs d’agrandissement $\times 2$, $\times 3$ et $\times 4$, en utilisant trois métriques complémentaires : PSNR, SSIM et LPIPS.

Les résultats quantitatifs et qualitatifs convergent vers des conclusions cohérentes. **SwinIR** se distingue comme le modèle le plus équilibré, offrant les meilleures performances en PSNR et SSIM tout en préservant la cohérence structurelle globale des images. **ESPCN** constitue la meilleure option pour les applications temps réel grâce à sa légèreté computationnelle. **Real-ESRGAN** et **CoSeR** se démarquent par leur qualité perceptive et leur rendu texturé visuellement riche, au prix de métriques pixeliques moins élevées. Le **modèle de diffusion** produit des résultats génératifs créatifs mais déviants des références originales, ce qui le rend plus adapté aux applications artistiques qu’à la reconstruction fidèle.

Dans la perspective d’une chaîne PCG, ces résultats permettent de formuler des recommandations d’intégration différenciées selon le type de contenu : ESPCN pour les géométries et heightmaps générées en masse, SwinIR pour les assets à haute précision

structurelle, et Real-ESRGAN ou CoSeR pour les éléments visuellement saillants. Une stratégie hybride, adaptant le choix du modèle au type de contenu, constitue l'approche la plus prometteuse pour concilier performance et qualité perceptive dans un pipeline PCG réaliste.

Perspectives. Pour la suite, les principaux axes d'amélioration identifiés concernent : (i) l'extension des expériences à un environnement GPU pour permettre des tests sur des architectures plus complexes et des images de plus grande taille ; (ii) la constitution d'un jeu de données spécifiquement orienté textures procédurales afin de mieux évaluer les modèles sur le type de contenu ciblé ; et (iii) l'intégration effective des modèles dans un pipeline PCG complet (génération $\rightarrow$ SR $\rightarrow$ rendu) afin de valider les recommandations en conditions réelles. Ces travaux futurs permettront de consolider les conclusions de ce rapport et de proposer des guidelines opérationnels pour les praticiens de la PCG.

Bibliographie

- [1] Syed Muhammad Arsalan BASHIR et al. “A comprehensive review of deep learning-based single image super-resolution”. In : *PeerJ Computer Science* 7 (2021), e621.
- [2] Yochai BLAU et Tomer MICHAELI. “The Perception-Distortion Tradeoff”. In : *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, juin 2018, p. 6228-6237. DOI : 10.1109/cvpr.2018.00652. URL : <http://dx.doi.org/10.1109/CVPR.2018.00652>.
- [3] Ming-Jun CHEN et Alan C BOVIK. “Fast structural similarity index algorithm”. In : *Journal of Real-Time Image Processing* 6.4 (2011), p. 281-287.
- [4] Chao DONG, Chen Change LOY et Xiaoou TANG. “Accelerating the super-resolution convolutional neural network”. In : *European conference on computer vision*. Springer, 2016, p. 391-407.
- [5] Rafael C. GONZALEZ et Richard E. WOODS. *Digital Image Processing*. 3^e éd. Pearson, 2008.
- [6] Michal IRANI et Shmuel PELEG. “Improving resolution by image registration”. In : *CVGIP : Graphical Models and Image Processing* 53.3 (1991), p. 231-239. ISSN : 1049-9652. DOI : [https://doi.org/10.1016/1049-9652\(91\)90045-L](https://doi.org/10.1016/1049-9652(91)90045-L). URL : <https://www.sciencedirect.com/science/article/pii/104996529190045L>.
- [7] Michal KAWULOK et al. “Deep learning for multiple-image super-resolution”. In : *IEEE Geoscience and Remote Sensing Letters* 17.6 (2019), p. 1062-1066.
- [8] Christian LEDIG et al. *Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network*. 2017. arXiv : 1609.04802 [cs.CV]. URL : <https://arxiv.org/abs/1609.04802>.
- [9] Christian LEDIG et al. “Photo-realistic single image super-resolution using a generative adversarial network”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017, p. 4681-4690.
- [10] Juncheng LI et al. “A systematic survey of deep learning-based single-image super-resolution”. In : *ACM Computing Surveys* 56.10 (2024), p. 1-40.
- [11] Jingyun LIANG et al. *SwinIR : Image Restoration Using Swin Transformer*. 2021. arXiv : 2108.10257 [eess.IV]. URL : <https://arxiv.org/abs/2108.10257>.
- [12] Hongying LIU et al. “Video super-resolution based on deep learning : a comprehensive survey”. In : *Artificial Intelligence Review* 55.8 (2022), p. 5981-6035.
- [13] Brian B. MOSER et al. *Diffusion Models, Image Super-Resolution And Everything : A Survey*. 2024. DOI : <https://doi.org/10.1109/TNNLS.2024.3476671>. arXiv : 2401.00736 [cs.CV]. URL : <https://arxiv.org/abs/2401.00736>.
- [14] Sung Cheol PARK, Min Kyu PARK et Moon Gi KANG. “Super-resolution image reconstruction : a technical overview”. In : *IEEE Signal Processing Magazine* 20.3 (2003), p. 21-36. DOI : 10.1109/MSP.2003.1203207.
- [15] A.J. PATTI, M.I. SEZAN et A. MURAT TEKALP. “Superresolution video reconstruction with arbitrary sampling lattices and nonzero aperture time”. In : *IEEE Transactions on Image Processing* 6.8 (1997), p. 1064-1076. DOI : 10.1109/83.605404.

- [16] D POOBATHY et R Manicka CHEZIAN. “Edge detection operators : Peak signal to noise ratio based comparison”. In : *IJ Image, Graphics and Signal Processing* 10 (2014), p. 55-61.
- [17] Shahryar QURESHI, Xue LI et Toufeeq AHMAD. “Investigating image super resolution techniques : What to choose?” In : *International Conference on Advanced Communication Technology, ICACT* (jan. 2012).
- [18] Robin ROMBACH et al. *High-Resolution Image Synthesis with Latent Diffusion Models*. 2022. arXiv : 2112.10752 [cs.CV]. URL : <https://arxiv.org/abs/2112.10752>.
- [19] Robin ROMBACH et al. “High-resolution image synthesis with latent diffusion models”. In : *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2022, p. 10684-10695.
- [20] Wenzhe SHI et al. “Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, p. 1874-1883.
- [21] Assaf SHOCHER, Nadav COHEN et Michal IRANI. ““zero-shot” super-resolution using deep internal learning”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, p. 3118-3126.
- [22] Karen SIMONYAN et Andrew ZISSERMAN. “Very deep convolutional networks for large-scale image recognition”. In : *arXiv preprint arXiv :1409.1556* (2014).
- [23] Haoze SUN et al. *CoSeR : Bridging Image and Language for Cognitive Super-Resolution*. 2023. arXiv : 2311.16512 [cs.CV]. URL : <https://arxiv.org/abs/2311.16512>.
- [24] Jing TIAN et Kai-Kuang MA. “A survey on super-resolution imaging”. In : *Signal, Image and Video Processing* 5 (2011), p. 329-342. URL : <https://api.semanticscholar.org/CorpusID:38840522>.
- [25] Xintao WANG et al. *Real-ESRGAN : Training Real-World Blind Super-Resolution with Pure Synthetic Data*. 2021. arXiv : 2107.10833 [eess.IV]. URL : <https://arxiv.org/abs/2107.10833>.
- [26] Frederick W. WHEELER et al. “Multi-Frame Image Restoration for Face Recognition”. In : *2007 IEEE Workshop on Signal Processing Applications for Public Security and Forensics*. 2007, p. 1-6. DOI : 10.1109/IEEECONF12259.2007.4218933.
- [27] Jianchao YANG et al. “Image Super-Resolution Via Sparse Representation”. In : *IEEE Transactions on Image Processing* 19.11 (2010), p. 2861-2873. DOI : 10.1109/TIP.2010.2050625.
- [28] Kai ZHANG, Wangmeng ZUO et Lei ZHANG. “Learning a single convolutional super-resolution network for multiple degradations”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, p. 3262-3271.
- [29] Richard ZHANG et al. “The unreasonable effectiveness of deep features as a perceptual metric”. In : *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, p. 586-595.